

Summer Institute in Computational Social Sciences


Cap. 0. Detectando tópicos en un corpus



¿Qué es NLP?



“Podemos imaginar que si conociéramos el conjunto de narraciones que circulan en la Ciudad de Buenos Aires en un día conoceríamos un tipo particular de funcionamiento de esta ciudad con bastante precisión. (...) Si tuviéramos la posibilidad, fantástica, de disponer de todas esas narraciones, podríamos detectar las grandes formas, los grandes núcleos formales a partir de los cuales se construyen **los grandes relatos sociales.**” (p. 60-61)



- Todo el tiempo estamos produciendo textos

- Charlas
- Entrevistas
- Posts
- Redes sociales



- ¿Cómo podemos aprovechar esos textos en la investigación?





“Mucha gente ha leído más y mejor que yo, por supuesto, pero eso tampoco basta: aquí hablamos de cientos de lenguas y literaturas. Todo indica que leer ‘más’ no es la solución. En especial, porque hemos comenzado a descubrir (...) la enormidad de lo no leído (...) pero el punto es que existen treinta mil novelas británicas del siglo XIX o cuarenta o cincuenta, sesenta mil: nadie lo sabe a ciencia cierta, nadie las ha leído, nadie las leerá. Y, además, hay novelas francesas, chinas, argentinas, estadounidenses.

Leer ‘más’ siempre es bueno, pero no es la solución” (p. 59)



El problema de los datos (la grieta)

- Lo “cualitativo”

- Constructivista/relativista
- Atención al detalle
- Lectura “cercana”
- Escala pequeña
- Fuerte presencia de lo subjetivo
- Poco escalable
- Centrada en el “sentido”

- Lo “cuantitativo”

- Positivista (?)
- Importancia de la generalidad
- Lectura “distante”
- Gran escala
- Intento de reproducibilidad
- Escalable
- Centrada en la “cantidad”



El problema de los datos (la grieta)

- Lo “cualitativo”

- Constructivista/relativista
- Atención al detalle
- Lectura “cercana”
- Escala pequeña
- Fuerte presencia de lo subjetivo
- Poco escalable
- Centrada en el “sentido”

Procesamiento de Lenguaje Natural

- Lo “cuantitativo”

- Positivista (?)
- Importancia de la generalidad
- Lectura “distante”
- Gran escala
- Intento de reproducibilidad
- Escalable
- Centrada en la “cantidad”



Estructura tripartita del dato (Galtung, 1973)

- Un dato está constituida por la Intersección de tres elementos:
 1. caso (unidad de análisis),
 2. un atributo (variable) y
 3. un valor (categoría) de esa variable.

i	V1	V2	...	Vp
1				
2				
3				
...				
n				



El problema de los datos

<<SimpleCorpus>>

Metadata: corpus specific: 1, document level (indexed): 0

Content: documents: 3

[1] a bailar a bailar | que la orquesta se va | sobre el fino garabato | de un tango nervioso y lerdo | se ira borrando el recuerdo | a bailar a bailar | que la orquesta se va | el ultimo tango perfuma la noche | un tango dulce que dice adios | la frase callada se asoma a los labios | y canta el tango la despedida! | vamos! a bailar! | tal vez no vuelvas a verla nunca | y el ultimo tango perfuma la noche | y este es el tango que dice el adios | a bailar a bailar | que la orquesta se va! | quedara el salon vacio | con un monton de esperanzas | que iran camino al olvido | a bailar a bailar | que la orquesta se va!

[2] este tango nacio para bailarse | y asi hamacarse muy suavemente | oigan ustedes este compas... | es muy sencillo bailar el tango | un doble paso despues descanso | la media vuelta la vuelta entera | y siempre junto a la companera | este tango nacio para bailarse | no hay que quedarse mirandolo

[3] nacio en la calle quito | entre boedo y colombres | barrio de tauras de hombres | de timbas y de garitos | mi recuerdo es muy estricto | de prosenio un corralon | modesto fue su blason | y la dulce purretita | se lavaba la carita | en el viejo pileton | amante del varietal | soñaba con ser artista | comenzo como corista | hasta llegar a vedette | piernas tipo mistinguette | cintura bien contorneada | anatomia envidiada | y un rostro angelical | para que plumas y percal | lucieran como hermanadas | siempre cause sensacion | en cine radio y teatro; | se volco al dos por cuatro | con sentida emocion | triunfo en television | y nadie podra dudar | fue figura consular | en todos los escenarios | recogio aplausos a diario | se llamaba beba bidart



El problema de los datos

MAS_500 Agglomerados segun tamaño	AGLOMERADO Codigo de Aglomerado	PONDERA Ponderacion	CH03 Relacion de parentesco	CH04 Sexo	CH05 Fecha de nacimiento (dia, mes y año)
N	8	108	2	2	03/06/1990
N	8	108	3	2	29/12/2005
N	8	108	3	1	26/01/2018
N	8	108	1	2	30/03/1978
N	8	108	3	2	20/09/2009
N	8	141	1	1	26/04/1967
N	8	221	1	1	15/03/1955
N	8	221	2	2	25/04/1956
N	8	221	3	2	10/06/1994
N	8	221	1	1	22/07/1944
N	8	221	3	1	23/08/1985
N	8	309	1	1	14/06/1976
N	8	309	2	2	17/06/1978
N	8	309	3	2	20/07/1997
N	8	309	3	1	19/10/2001
N	8	309	1	2	02/01/1967
N	8	309	3	2	29/06/1982
N	8	88	1	1	15/08/1974

14/06/1976



El problema de los datos

```
<<SimpleCorpus>>
Metadata: corpus specific: 1, document level (indexed): 0
Content: documents: 3
```

[1] a bailar a bailar | que la orquesta se va | sobre el fino garabato | de un tango nervioso y llerdo | se ira borrando el recuerdo | a bailar a bailar | que la orquesta se va | el ultimo tango perfuma la noche | un tango dulce que dice adios | la frase callada se asoma a los labios | y canta el tango la despedida! | vamos! a bailar! | tal vez no vuelvas a verla nunca | y el ultimo tango perfuma la noche | y es te es el tango que dice el adios | a bailar a bailar | que la orquesta se va! | quedara el salon vacio | con un monton de esperanzas | que iran camino al olvido | a bailar a bailar | que la orquesta se va!

[2] este tango nacio para bailarse | y asi hamacarse muy suavemente | oigan ustedes este compas... | es muy sencillo bailar el tango | un doble paso despues descanso | la media vuelta la vuelta entera | y siempre junto a la companera | este tango nacio para bailarse | no hay que quedarse mirandolo

[3] nacio en la calle quito | entre boedo y colombres | barrio de tauras de hombres | de timbas y de garitos | mi recuerdo es muy estricto | de proscenio un corralon | modesto fue su blason | y la dulce purrética | se lavaba la carita | en el viejo pileton | amante del varieté | soñaba con ser artista | comenzo como corista | hasta llegar a vedette | piernas tipo mistiguette | cintura bien contorneada | anatomía envidiada | y un rostro angelical | para que plumas y percal | lucieran como hermanadas | siempre causo sensacion | en cine radio y teatro; | se volco al dos por cuatro | con sentida emocion | triunfo en television | y nadie podra dudar | fue figura consular | en todos los escenarios | recogio aplausos a diario | se llamaba beba bidart

MAS_500	AGLOMERADO	PONDERA	CH03	CH04	CH05
Agglomerados segun tamano	Codigo de Aglomerado	Ponderacion	Relacion de parentesco	Sexo	Fecha de nacimiento (dia, mes y año)
N		8	108	2	2 03/06/1990
N		8	108	3	2 29/12/2005
N		8	108	3	1 26/01/2018
N		8	108	1	2 30/03/1978
N		8	108	3	2 20/09/2009
N		8	141	1	1 26/04/1967
N		8	221	1	1 15/03/1955
N		8	221	2	2 25/04/1956
N		8	221	3	2 10/06/1994
N		8	221	1	1 22/07/1944
N		8	221	3	1 23/08/1985
N		8	309	1	1 14/06/1976
N		8	309	2	2 17/06/1978
N		8	309	3	2 20/07/1997
N		8	309	3	1 19/10/2001
N		8	309	1	2 02/01/1967
N		8	309	3	2 29/06/1982
N		8	88	1	1 15/08/1974



Grado de estructuración



factor-data
EIDAEs_UNSAM

El problema de los datos

- No estructurados
- No hay modelo predefinido
- No hay orden
- NLP => tratar de detectar patrones en estos datos no estructurados
- Área de investigación científica llamada Natural Language Processing, una subdisciplina de machine learning/ciencias de la computación que trata de emular la interpretación humana de textos.




Problemas de aplicación

- Supervisado: Clasificación de textos en categorías definidas anteriormente
- No supervisado: no hay variable dependiente. Técnicas exploratorias. Detección de temas, entrenamiento de word embeddings, etc.

Aplicaciones usuales

SENTIMENT ANALYSIS



factor-data
EIDAES_UNSAM

Clasificación - Aplicaciones

Automatización de procesos
para la construcción de bases
de datos de protestas

[\[Hanna, 2017\]](#)




Figure 1: MPEDS pipeline with training.


No supervisado - Aplicaciones

Posiciones ideológicas en proyectos de ley

[\[Gerrish y Blei, 2012\]](#)

Terrorism	Commemorations	Transportation
terrorist	nation	transportation
september	people	minor
attack	life	print
nation	world	tax
york	serve	land
terrorist attack	percent	guard
hezbollah	community	coast guard
national guard	family	substitute

Labeled topics



The issue-adjusted ideal point model

Figure 3: Left: Top words from topics fit using labeled LDA [6]. Right: the issue-adjusted ideal point model, which models votes v_{ud} from lawmakers and legislative items. Classic item response theory models votes v using x_u and a_d, b_d . For our work, documents' issue vectors θ were estimated fit with a topic model (left of dashed line) using bills' words w and labeled topics β . Expected issue vectors $\mathbb{E}_q[\theta|w]$ are then treated as constants in the issue model (right of dashed line).

Un flujo de trabajo “típico” en NLP



Flujo de trabajo en NLP - Preprocesamiento

- Limpieza del texto (texto característico de los formatos)
- Cambiar mayúsculas por minúsculas
- Eliminar signos de puntuación y caracteres extraños (#\$%&?'!.,)
- Eliminar números (1,2,3,4...)
- Eliminar “stopwords”



Flujo de trabajo en NLP - Preprocesamiento

- Exclusión de palabras muy comunes con poco valor para recuperar información del documento o corpus
- La cantidad de ocurrencias de una palabra en el texto determina si es o no una “stopword” cuanto más ocurrencias existan menos relevancia tiene en el texto.
- Artículos, pronombres, preposiciones, y conjunciones.
- Reducir el tamaño del texto para analizar, eliminando aproximadamente el 30 % o 40 % de dichas palabras.

Flujo de trabajo en NLP - Preprocesamiento

- Limpieza del texto (texto característico de los formatos)
- Cambiar mayúsculas por minúsculas
- Eliminar signos de puntuación y caracteres extraños (#\$%&?'!.,)
- Eliminar números (1,2,3,4...)
- Eliminar “stopwords”
- Tokenización...

Flujo de trabajo en NLP - Preprocesamiento

- Tokenización: proceso que divide una secuencia (por ejemplo, una oración) en *tokens*
- Un *token* puede ser pensada como una unidad útil para el procesamiento semántico (oraciones, párrafos, documentos, etc.)
- Sistemas de escritura occidental: los espacios en blanco y ciertas formas de puntuación (puntos, comas, etc.) son delimitadores útiles para identificar tokens



Flujo de trabajo en NLP - Preprocesamiento

- Input:
 - [No es la conciencia (...) la que determina su ser sino (...) el ser social lo que determina su conciencia.]
- Output:
 - [No], [es], [la], [conciencia], [la], [que], [determina], [su], [ser], [sino], [el], [ser], [social], [lo], [que], [determina], [su], [conciencia]

Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”



Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”

Flujo de trabajo en NLP - Preprocesamiento

The logo for the stemming process, featuring the word "Stemming" in a blue box. The "Stem" part is white and the "ming" part is red.

Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”

“Affect” “Affect” “Affect” “Affect” “Affect” “Affect”



Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”

“Affect” “Affect” “Affect” “Affect” “Affect” “Affect”

Inconveniente: No funciona siempre. Hay palabras que **su raíz depende del contexto** de la oración. Se requiere un **análisis morfológico**.

Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)



Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)

El lema es la palabra que nos encontraríamos en el diccionario tradicional:



Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)

El lema es la palabra que nos encontraríamos en el diccionario tradicional:

- singular para sustantivos (“Mesa” -> “Mesas”)
- masculino singular para adjetivos (“guapas” -> “guapo”)
- infinitivo para verbos (“dije”, “diré”, “dijéramos” -> “decir”)



Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)

El lema es la palabra que nos encontraríamos en el diccionario tradicional:

- singular para sustantivos (“Mesa” -> “Mesas”)
- masculino singular para adjetivos (“guapas” -> “guapo”)
- infinitivo para verbos (“dije”, “diré”, “dijéramos” -> “decir”)

Similar a **stemming** ya que mapea muchas palabras a una sola pero el resultado de **lemmatization** es una palabra mientras que en stemming puede no serlo




Presentación del problema



Polarización en medios

- ¿Es posible detectar “temas” polarizantes?
- Dado el rol que pueden llegar a tener los medios (tradicionales o modernos) en la generación y seteo de la agenda pública es importante poder detectar la existencia de “temas” que polarizan la opinión.



Estrategia metodológica


- Datasets
 - Corpus de noticias de medios digitales
 - Corpus de comentarios sobre esas noticias
 - Corpus de discursos presidenciales
- Detección de temas en medios digitales
- Construcción de métricas de polarización
 - # de comentarios negativos
 - # de comentarios positivos
- Clasificación de temas y noticias según polarización
- Detección de discursos presidenciales polarizantes



¿Cómo representar “matemáticamente” un texto?



Document-Term Matrix (DTM)




Document-Term Matrix (DTM)

Palabras, bigramas,
trigramas, lemas, solo la
raíz de la palabra...

F términos

Matriz $M =$



Frecuencia del término

Bag of Words (BoW)

- Representación de cada documento en función de las palabras que contiene
- Características:
 - Es simple de generar
 - Se asume que las palabras son “independientes”
 - Los vectores son claramente no independientes
 - La gramática y el orden de las palabras se pierden



Modelado de tópicos



¿Qué es?

- ¿Cómo detectamos los temas de un corpus sin leerlo y sin buscar palabras específicas?
- Tenemos un corpus documental muy grande y queremos una herramienta para hacer una primera “lectura” sin leer uno por uno los documentos.



¿Qué es?

- Las técnicas de modelado de tópicos apuntan a eso: buscan detectar grupos o conjuntos de textos con una temática similar. Algoritmos basados en descomposición de matrices (NMF: Non-Negative Factorization) y modelos probabilísticos (LDA: Latent Dirichlet Allocation).
- Hoy vamos a centrarnos en LDA.



- La matriz de documentos-términos suele tener muchos ceros
- Problema: se hace difícil medir la relación entre los distintos documentos o términos

	Palabra 1	Palabra 2	Palabra 3	Palabra 4	Palabra 5	
Relato 1	0	0.12	0.01	0	0	
Relato 2	0	0	0.44	0.15	0.65	
Relato 3	0.11	0.31	0.28	0	0	(...)
Relato 4	0	0	0.05	0.21	0	
Relato 5	0	0.13	0	0.07	0	
			(...)			


La correlación lineal entre filas nos da una idea de la similitud del significado entre relatos

La correlación lineal entre columnas nos da una idea de la similitud del significado entre palabras

Pero hay un problema: la mayor parte de los valores son 0




¿Qué es un tópico?



¿Cómo se ve una matriz de documentos por términos real?

En blanco las componentes igual a cero; en negro las componentes distintas de cero.


¿Qué es un tópico?



Ordenando la matriz por
filas y columnas...



¿Qué es un tópico?



Emergencia de bloques: Conjunto de **documentos que usan términos similares**. Estos bloques emergen naturalmente del “ordenamiento” de la matriz de documentos por términos.

A los bloques los identificamos como **tópicos** o **ejes temáticos**.

¿Cómo hacemos el ordenamiento?
Algoritmos de detección de tópicos


Latent Dirichlet Allocation (LDA)

Modelo probabilístico generativo (modelo para describir la forma en que se produjo la TFM)

Supuestos:


- un tópico es una distribución en el espacio de términos;
- un documento es una distribución en el espacio de tópicos (es una mixtura de tópicos).

Latent Dirichlet Allocation (LDA)




Latent Dirichlet Allocation (LDA)

¿Cuál es el modelo generativo? La idea es ir construyendo término a término un documento. Supongamos que ya conocemos todas las distribuciones:



Elijo un tópico de la
distribución del
documento en el espacio
de tópicos




```
gene    0.04  
dna     0.02  
genetic 0.01  
...
```

```
life     0.02  
evolve  0.01  
organism 0.01  
...
```

```
brain    0.04  
neuron   0.02  
nerve    0.01  
...
```

```
data     0.02  
number   0.02  
computer 0.01  
...
```




Elijo un término de la
distribución del tópico
elegido en el espacio de
términos

El término elegido forma
parte del documento e
itero hasta completar
los N términos del
documentos

Latent Dirichlet Allocation (LDA)

¿Dónde está el problema? En tratar de inferir las distribuciones de los documentos y tópicos a partir de los datos.



Latent Dirichlet Allocation (LDA)

Algorithm

LDA assumes the following generative process for each document $\mathbf{w}$ in a corpus $\mathcal{D}$:

1. Choose $N \sim \text{Poisson}(\xi)$.
2. Choose $\theta \sim \text{Dir}(\alpha)$.
3. For each of the N words w_n :
 - (a) Choose a topic $z_n \sim \text{Multinomial}(\theta)$.
 - (b) Choose a word w_n from $p(w_n | z_n, \beta)$, a multinomial probability conditioned on the topic z_n .

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent dirichlet allocation. *the Journal of machine Learning research*, 3, 993-1022.



Latent Dirichlet Allocation (LDA)




Figure 1: Graphical model representation of LDA. The boxes are “plates” representing replicates. The outer plate represents documents, while the inner plate represents the repeated choice of topics and words within a document.

Latent Dirichlet Allocation (LDA)

No vamos a ver en detalle la matemática ni los procesos de estimación pero esta ecuación da una intuición de lo que está pasando:

$$p(\mathbf{w} | \alpha, \beta) = \int p(\theta | \alpha) \left(\prod_{n=1}^N \sum_{z_n} p(z_n | \theta) p(w_n | z_n, \beta) \right) d\theta.$$


Proba de obtener un documento dado parámetros del modelo

Probabilidad de elegir el tópico del documento

Proba de elegir un término dado un tópico

Objetivo: inferir estos objetos (a través de inferir los parámetros de las distintas distribuciones).

Del texto crudo al texto como dato




De la matriz de términos a la matriz de tópicos

	hurlingham	noche	paisano	pompeya	techos	vernes
C1	1	1	1	0	0	0
C2	0	0	0	1	1	0
C3	0	1	0	0	0	1



Matriz de Frecuencia de términos

	hurlingham	noche	paisano	pompeya	techos	vernes
T1	0.8	0.4	0.8	0.9	0.6	0.2
T2	0.3	0.9	0.1	0.3	0.4	0.9



Matriz de Términos x Tópicos

Matriz de Documentos x Tópicos



	T1: Barrios	T2: Fiesta
C1	0.9	0.1
C2	0.9	0.1
C3	0.15	0.85




Latent Dirichlet Allocation (LDA)

Ventajas de los modelos generativos:

- Supuestos explícitos: si el modelo falla (por ejemplo, no encuentra los tópicos correctos en un corpus bien definido) se puede chequear si es porque los datos no cumplen alguna. De variar las hipótesis vienen las extensiones de LDA (Structural Topic Modeling es una de las variantes más conocidas).
- Generación de datos sintéticos y autoconsistencia: podemos inicializar el modelo con ciertos parámetros, generar datos sintéticos y ver si recuperamos los parámetros originales.

Un caso de aplicación (autobombo)



“El tango, como hemos visto, empezó, surge de la milonga, y es al principio un baile valeroso y feliz. Y luego, el tango va languideciendo y entristeciéndose...”

III Conferencia, p.80-81

Enfoque tradicional

- Problema: analizar los temas de las letras de tango
- Enfoque “hermenéutico”: analizar pocas letras en profundidad
- Temas comunes: representaciones de género, figuras del “guapo”, representaciones del arrabal, etc.




Enfoque tradicional

- Problema: analizar los temas de las letras de tango
- Enfoque “estadístico”
- Cantón (1972), analiza ciertos aspectos relevantes de las letras de los tangos cantados por Gardel



Enfoque propio

- Scrap de letras del sitio todotango.com
- Corpus: 5.700 letras
- Problema: analizar un corpus de ~5.700 letras de tango para detectar “tópicos” - Detección automática: Latent Dirichlet Allocation



A screenshot of a web page titled "Afiches" from the website todotango.com. The page displays the lyrics of a tango song. At the top, it identifies the song as "Tango", the music as "Música: Atilio Stampone", and the lyrics as "Letra: Homero Expósito". Below this, there are social media interaction buttons: "Me gusta 115", "Compartir", and "Twitter". A navigation bar contains four tabs: "Música", "Letra" (which is highlighted in yellow), "Video", and "Versiones". The main content area shows the lyrics in a light green font on a dark background. The lyrics are divided into two stanzas. The first stanza begins with "Cruel en el cartel," and the second with "Ya da la noche a la cancel".

Afiches
Tango
Música: Atilio Stampone
Letra: Homero Expósito
Me gusta 115 Compartir Twitter
Música Letra Video Versiones

Cruel en el cartel,
la propaganda manda cruel en el cartel,
y en el fetiche de un afiche de papel
se vende la ilusión,
se rifa el corazón...
Y apareces tú
vendiendo el último jirón de juventud,
cargándome otra vez la cruz.
¡Cruel en el cartel, te ríes, corazón!
¡Dan ganas de balearse en un rincón!

Ya da la noche a la cancel
su piel de ojera...
Ya moja el aire su pincel
y hace con él la primavera...
¿Pero qué?
si están tus cosas pero tú no estás,
porque eres algo para todos,
como un desnudo de vidriera...
¡Luché a tu lado, para ti,
por Dios, y te perdí!



12 temas detectados



factor-data
EIDAES_UNSAM

01 Imágenes climáticas

después estrella
nombre sombra tiempo
espera viento final
sueño sol luna tarde
vez cielo adiós
ojos noche piel
luz voz dos
manos mar gris
sueños calle soledad
silencios sombras
camino

05 Campo y gauchesca

bajo muerto
gloria dios juan pronto
hizo rancho allí
china dio dió habia vio
dije pobre tierra tenia criollo
grito don iba patria
pampa gaucho huella perro
largo llevo después
camino blanca

09 Emociones negativas

mujer penas
pobre carino cruel
vivir querer mal
alma dolor llorar
solo vida hoy
dia amor vez
corazon mia
quiero pena
lado nunca siento
siempre puedo ojos

02 Ciudad, imágenes urbanas

libre historia
nueva siempre pueblo
esquina algún
quiere pais
calles aires aire
sur ali
plaza cada rio vino
libertad toda lugar
luces buenos
abrazo ciudad mil
gusta ciudad hijos
encuentro gente

06 Tango y arrabal

porteño cantando
gardel emocion notas
cancion arrabal triste
compas canto cantor
cantar barrio viejo
bajo baile
alma paris
voz tango
milonga bailar
bandoneon tangos
canta corazon hace
guitarra muchachos
percal

10 Candombe

sueño morena
charol ropa
seda coro niño candombe
sangre negra loca
saben risa negro blanco
loco hace cuerpo
negros pelo maria
dio carnaval hacen
mismo agua pasar
mundo

03 Misc

gitar cruz
triste alguien fuerte
medio mano ocura
aun dice momento dia
mia pues toda fondo copa
van historia voy razon
mundo sigue loco aqui
cabeza entero cara
almas venga

07 Tiempo, recuerdos

aquellos viejos
noches aquella entonces
recuerdos dias
cosas años queda
volver tiempo vez
vida hoy vieja van
están ahora
igual viejo ayer
recuerdo nuevo
amigos pasado lejos
barrio parece horas
siempre

11 Misc y familia

grito dinero
domingo alla niños
veo casi lado coraje
alegría dia hizo pie
hora toda
dichos rato
alcanza sangre
cerca deja pues vieja
quede queda

04 Emociones positivas

soñar toda
noches amores canto
flores pasión linda
dulce ojos labios
corazon feliz
amor sol
luz flor alma
ilusion cancion
emocion mujer junto
sueño ternura querer


08 Misc

cosas
dicen dios verdad bien
amigo hombre nunca
puede vida aunque
ver mundo vivir
dos ser nadie
siempre mano
sabe voy aqui mejor
sera mismo gente
vamos mañana
andar hacer


12 Misc y lunfardo

bronca pinta haces
pal sabes bulin
hace tenes suerte
hoy vassos ves anda
pibe pobre vos buen
che
mina bien gran hecho
bacan bien gran cara
hermano queres
después ver
juego

Composición de tópicos de 4 tangos




Evolución de los tópicos, 1900-2010 (suavizado GAM)



No supervisado - Aplicaciones

Detección de temas en comentarios a noticias sobre COVID-19

[[Rosati, Chazarreta, Domenech y Maguire, 2023](#)]



Resumen

- La TFM es un insumo para detectar tópicos
- Un “tópico” emerge como un de términos comunes usados por ciertos conjunto de documentos
- LDA es un método generativo para esa tarea



Vamos al notebook...



Parte Hands-on



¿Cómo vamos a trabajar?

- 4 grupos - 5 integrantes cada uno
- Diversos: al menos un integrante con conocimiento de Python y un integrante con conocimiento de NLP
- Campaña presidencial 2015: Grupos 1 y 2
- Campaña presidencial 2019: Grupos 3 y 4
- Cada campaña tiene dos muestras independientes de noticias ($n=10.000$) y de los comentarios asociados a esas noticias



Consignas orientadoras

1. Cargar el dataset de noticias correspondiente
2. Preprocesarlo
3. Determinar una cantidad significativa de tópicos en las noticias (deberán iterar varias veces para dar con un k útil). Debe ser lo suficiente granular como identificar temas específicos e interpretable
4. Etiquetar cada tópico en función de la relevancia de cada palabra
5. Diseñar y ejecutar una estrategia de validación

