

factor~data
EIDAES_UNSAM



Summer Institute in Computational Social Sciences
Buenos Aires-Argentina | 2026

Del giro lingüístico al giro (lingüístico) computacional. ¿Qué son las Ciencias Sociales Computacionales?

Germán Rosati (CONICET / factor~data-EIDAES-UNSAM / PIMSA)

Adriana Chazarreta (CONICET / factor~data-EIDAES-UNSAM)

Florencia Piñeyrúa (factor~data-EIDAES-UNSAM)

Nayla Sol Garcilazo (factor~data-EIDAES-UNSAM)



factor~data
EIDAES_UNSAM



Summer Institute in Computational Social Sciences
Buenos Aires-Argentina | 2026

¿Qué son las CSC?

- Campo disciplinar en formación (o reformación)
- Muchas definiciones por “extensión” o “aglomeración”
- Énfasis en que son “Ciencias Sociales”
- Enfoque nada novedoso



Las Ciencias Sociales Computacionales, también conocidas como Computational Social Sciences en inglés, se refieren a un campo interdisciplinario que combina la teoría y métodos de las ciencias sociales con la computación y el análisis de datos. El objetivo principal de las Ciencias Sociales Computacionales es utilizar enfoques cuantitativos y computacionales para comprender mejor los fenómenos sociales y humanos.

Este campo surge de la creciente disponibilidad de datos digitales y la capacidad de procesarlos a gran escala gracias a avances en la tecnología de la información y la comunicación. Algunos ejemplos de datos utilizados en las Ciencias Sociales Computacionales incluyen publicaciones en redes sociales, registros de transacciones económicas, datos demográficos, registros de llamadas telefónicas, entre otros.

Las Ciencias Sociales Computacionales abarcan una amplia gama de temas, incluyendo:

1. **Análisis de redes sociales:** Estudia las relaciones entre individuos, organizaciones o entidades a través del análisis de sus conexiones en redes.
2. **Minería de textos:** Analiza grandes cantidades de datos de texto, como comentarios en redes sociales, para extraer patrones y tendencias.
3. **Modelado de opinión y sentimiento:** Utiliza técnicas computacionales para determinar la opinión y el sentimiento expresados en datos, como reseñas en línea.
4. **Predicción y modelado social:** Emplea algoritmos y modelos estadísticos para predecir tendencias y comportamientos en la sociedad.
5. **Simulación y modelado de sistemas sociales:** Crea modelos computacionales que simulan interacciones sociales y permiten explorar cómo se propagan ciertos comportamientos o fenómenos.
6. **Economía computacional:** Utiliza modelos computacionales para estudiar cuestiones económicas y de comportamiento en mercados y sistemas económicos.
7. **Política y análisis de políticas públicas:** Examina datos relacionados con la política y la toma de decisiones para comprender mejor los procesos políticos.
8. **Ciencias sociales experimentales en línea:** Realiza experimentos sociales utilizando plataformas en línea y datos digitales.
9. **Geolocalización y análisis espacial:** Analiza datos geográficos y espaciales para comprender patrones de movimiento y distribución.

Las Ciencias Sociales Computacionales han transformado la forma en que los investigadores estudian y analizan los fenómenos sociales, permitiendo un enfoque más basado en datos y menos en teoría. Sin embargo, también plantean desafíos éticos y metodológicos, como la privacidad de los datos, la interpretación adecuada de los resultados y la necesidad de equilibrar enfoques cuantitativos con comprensión cualitativa de los contextos sociales.

¿Qué son las Ciencias Sociales Computacionales?



ISSN: 1666-12576

Ciencias Sociales Computacionales Un estado de la cuestión y una agenda de investigación

Germán Rosati,¹ Adriana Chazarreta,²
Laia Domenech Burin,³ Florencia Piñeyrúa⁴
y Tomás Maguire⁵

- Campo disciplinar en formación (o reformulación)
- Muchas definiciones por “extensión” o “aglomeración”

- Énfasis en que son “**Ciencias Sociales**”
- Enfoque nada novedoso

Resumen

El presente trabajo tiene como objetivo trazar un panorama general de las Ciencias Sociales Computacionales (CSC). Se argumenta que se trata menos de una disciplina *ad-hoc* que de un giro metodológico en las Ciencias Sociales. Se destacan tres características fundamentales de las CSC y se ilustran con algunas investigaciones llevadas adelante en la Escuela IDAES-UNSAM.

Palabras clave: ciencias sociales computacionales; aprendizaje automático; metodología de la investigación

Abstract

This paper aims to provide an overview of Computational Social Sciences (CSS). It argues that CSS is less of an *ad-hoc* discipline and more of a methodological shift in the Social Sciences. Three fundamental characteristics of CSS are identified and exemplified through research conducted at EIDAES-UNSAM.

Keywords: computational social sciences; machine learning; research methodology

¹ Factor -data - Escuela Interdisciplinaria de Estudios Sociales - Universidad Nacional de San Martín, Consejo Nacional de Investigaciones Científicas y Técnicas, german.rosati@gmail.com, ORCID: 0000-0002-9775-0435.

² Factor -data - Escuela Interdisciplinaria de Estudios Sociales - Universidad Nacional de San Martín, Consejo Nacional de Investigaciones Científicas y Técnicas, adchazarreta@gmail.com, ORCID: 0000-0002-4737-9578.

³ Factor -data - Escuela Interdisciplinaria de Estudios Sociales - Universidad Nacional de San Martín, laiadomenechburin@gmail.com, ORCID: 0000-0003-4576-3143.

⁴ Factor -data - Escuela Interdisciplinaria de Estudios Sociales - Universidad Nacional de San Martín, Consejo Nacional de Investigaciones Científicas y Técnicas, pinleyruea@gmail.com, ORCID: 0000-0002-2043-8240.

⁵ Factor -data - Escuela Interdisciplinaria de Estudios Sociales - Universidad Nacional de San Martín, tomasmaguire@gmail.com, ORCID: 0000-0001-6511-4728.

THE END OF THEORY: THE DATA DELUGE MAKES THE SCIENTIFIC METHOD OBSOLETE



“Olvídense de la teoría del comportamiento humano, desde la lingüística hasta la sociología. Olvídense de las taxonomías, de la ontología y de la psicología. ¿Quién sabe por qué la gente hace lo que hace?. El punto es que lo hacen y que podemos trackear y medir eso que hacen con una precisión sin precedentes. Con suficientes datos, los números hablan por sí mismos.”

the process. Our records are increasingly full of data obtained by introspection or by extrospection of what we take to be the behaviors of ourselves and others. Many procedures have been invented to relate the observer to his field of observation and to produce a record that can be related to the terms of an explanatory model.

Nuestros registros están cada vez más llenos de datos obtenidos por introspección o por extrospección de lo que consideramos comportamientos de nosotros mismos y de los demás. Se han inventado muchos procedimientos para relacionar el observador a su campo de observación y producir un registro que puede relacionarse con los términos de un modelo explicativo.

THE GENERAL INQUIRER
SOME STRONG FEELINGS CO
BUY ME JUST A GUITAR I AM
AT SHE AND A GIRL A COMPUTER
SUALLY GO TO THE APPROACH
POOL I CANNOT SWIM TO
HEM IF YOU FALL IN. CONTENT
OF THE CONSIDER ANALYSIS
ON NOTHING THAT IS OLD TH
SO THE BOYS WOULD STUDIES IN
SAID. TAKE OFF A PSYCHOLOGY
CE. YOU KNOW, HE SOCIOLOGY
THOUGHT THAT HE ANTHROPOLOGY
IS YOUR FACE NOW MMM TO AND
/88 THINK/9 YOU/1 POLITICAL
THINK HE WILL FINAL SCIENCE
NOT WAIT UNTIL HE WOULD GET
IT PLAY. AND PHILIP J. STONE
. AND I WILL DEXTER C. DUNPHY
AS IT MADE MARSHALL S. SMITH
HE PROBABLY DANIEL M. OGILVIE
ELSE. HE MUST HAVE LEARN
E CAN MAKE MONEY BY LEARNI

The emergence of the computer has made it feasible for social and behavioral scientists to make a fresh start on content analysis. The vast potentialities of content analysis, though foreseen for some years, have been poorly realized, owing chiefly to the onerous task of scanning texts and processing data. The latter operation — data processing — has been successfully improved, and there is promise of automatic scanners that, when appropriately joined with panels of human judges, will accelerate the turning of raw records into data.

La aparición de la computadora ha hecho posible que las comunidades sociales y científicos del comportamiento para comenzar de nuevo el análisis de contenido. El enormes potencialidades del análisis de contenidos, aunque previstas desde hace algunos años, han sido mal realizados, debido principalmente a la onerosa tarea de escanear elaboración de textos y procesamiento de datos. La última operación -proceso de datos- se ha mejorado con éxito y hay promesas de scanners automáticos que, cuando se unen adecuadamente con paneles de humanos jueces, acelerará la conversión de registros sin procesar en datos.

THE GENERAL INQUIRER
SOME STRONG FEELINGS CO
BUY ME JUST A GUITAR I AM
AT SHE AND A GIRL A COMPUTER
USUALLY GO TO THE APPROACH
POOL I CANNOT SWIM TO
HEM IF YOU FALL IN. CONTENT
OF THE CONSIDER ANALYSIS
ON NOTHING THAT IS OLD TH
SO THE BOYS WOULD STUDIES IN
SAID. TAKE OFF A PSYCHOLOGY
CE. YOU KNOW, HE SOCIOLOGY
THOUGHT THAT HE ANTHROPOLOGY
IS YOUR FACE NOW MMM TO AND
/88 THINK/9 YOU/1 POLITICAL
THINK HE WILL FINAL SCIENCE
NOT WAIT UNTIL HE WOULD GET
IT PLAY. AND PHILIP J. STONE
. AND I WILL DEXTER C. DUNPHY
AS IT MADE MARSHALL S. SMITH
HE PROBABLY DANIEL M. OGILVIE
ELSE. HE MUST HAVE LEARN
E CAN MAKE MONEY BY LEARNI

“La IA de nivel humano se superará a mediados de la década del 2020”

Shane Legg, cofundador de Google DeepMind, **2016**

“Las máquinas serán capaces, dentro de 20 años de hacer cualquier tarea que pueda hacer un hombre”

Herbert Simon, economista, premio Nobel, **1964**

“Dentro de una generación (...) los problemas de crear una Inteligencia Artificial estarán esencialmente resueltos”

Marvin Minsky, fundador del Laboratorio de Inteligencia Artificial (MIT), **1967**

El primer chatbot...

- ELIZA, creado por Joseph Weizenbaum en el MIT (Massachusetts Institute of Technology).
- Experimento para mostrar cómo las computadoras podían simular una conversación humana de manera superficial.

```
Welcome to

EEEEEE LL      IIII ZZZZZZ  AAAAA
EE      LL      II      ZZ   AA  AA
EEEEEE LL      II      ZZZ   AAAAAA
EE      LL      II      ZZ   AA  AA
EEEEEE LLLLLL IIII ZZZZZZ  AA  AA

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.

ELIZA: Is something troubling you ?
YOU:   Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU:   They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU:   Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU:   He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU:   It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:
```

Simulador: <https://anthay.github.io/eliza.html>

Sitio "arqueológico": <https://sites.google.com/view/elizagen-org/About?authuser=0>

El primer chatbot...

- DOCTOR: imitaba a un psicoterapeuta rogeriano
- Respondía con preguntas o reformulaciones a lo que el usuario escribía
- Muchas personas creyeron que ELIZA realmente las comprendía
- Garfinkel trabajó con ELIZA

```
Welcome to

EEEEEE LL      IIII  ZZZZZZ  AAAAA
EE      LL      II    ZZ      AA  AA
EEEEEE LL      II    ZZ      AAAAAA
EE      LL      II    ZZ      AA  AA
EEEEEE LLLLLL IIII  ZZZZZZ  AA  AA

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.

ELIZA: Is something troubling you ?
YOU:   Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU:   They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU:   Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU:   He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU:   It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:
```

Simulador: <https://anthay.github.io/eliza.html>

Sitio "arqueológico": <https://sites.google.com/view/elizagen-org/About?authuser=0>


En realidad se veía así...



<https://sites.google.com/view/elizaarchaeology/blog/2-talking-to-eliza-on-an-asr-33-teletype>

Immigrant community integration in world cities

- Medir la segregación/integración de comunidades migrantes
- 52 ciudades
- Datos de Twitter
- Búsqueda de lugares de residencia habituales
- Detección de lenguaje
- Cálculo de índices de segregación



LLMs e investigación en Ciencias Sociales

- Fidelidad algorítmica
- Replicación de otro estudio
- “Muestreo de silencio”
- Generación de un dataset a partir de un perfil ideológico “prototípico”-
- Se le pidió a GPT3 que generara palabras describiendo a demócratas y republicanos

	Describing Democrats	Describing Republicans
Strong Republicans	Ideologically, I describe myself as <u>conservative</u> . Politically, I am a <u>strong Republican</u> . Racially, I am <u>white</u> . I am <u>male</u> . Financially, I am <u>upper-class</u> . In terms of my age, I am <u>young</u> . When I am asked to write down four words that typically describe people who support the <u>Democratic</u> Party, I respond with: 1. <u>Liberal</u> 2. <u>Socialist</u> 3. <u>Communist</u> 4. <u>Atheist</u> .	Ideologically, I describe myself as <u>conservative</u> . Politically, I am a <u>strong Republican</u> . Racially, I am <u>white</u> . I am <u>male</u> . When I am asked to write down four words that typically describe people who support the <u>Republican</u> Party, I respond with: 1. <u>Conservative</u> 2. <u>Male</u> 3. <u>White (or Caucasian)</u> 4. <u>Christian</u> .
Strong Democrats	Ideologically, I describe myself as <u>liberal</u> . Politically, I am a <u>strong Democrat</u> . Racially, I am <u>white</u> . I am <u>female</u> . Financially, I am <u>poor</u> . In terms of my age, I am <u>old</u> . When I am asked to write down four words that typically describe people who support the <u>Democratic</u> Party, I respond with: 1. <u>Liberal</u> . 2. <u>Young</u> . 3. <u>Female</u> . 4. <u>Poor</u> .	Ideologically, I describe myself as <u>extremely liberal</u> . Politically, I am a <u>strong Democrat</u> . Racially, I am <u>hispanic</u> . I am <u>male</u> . Financially, I am <u>upper-class</u> . In terms of my age, I am <u>middle-aged</u> . When I am asked to write down four words that typically describe people who support the <u>Republican</u> Party, I respond with: 1. <u>Ignorant</u> 2. <u>Racist</u> 3. <u>Misogynist</u> 4. <u>Homophobic</u> .

Figure 1. Example contexts and completions from four silicon “individuals” analyzed in Study 1. Plaintext indicates the conditioning context; underlined words show demographics we dynamically inserted into the template; blue words are the four harvested words.

Out of One, Many:
Using Language Models to Simulate Human Samples

Lisa P. Argyle¹, Ethan C. Busby¹, Nancy Fulda², Joshua Gubler¹, Christopher Rytting², and David Wingate²

¹Department of Political Science, Brigham Young University
²Department of Computer Science, Brigham Young University

September 16, 2022

Abstract

We propose and explore the possibility that language models can be studied as effective proxies for specific human sub-populations in social science research. Practical and research applications of artificial intelligence tools have sometimes been limited by problematic biases (such as racism or sexism), which are often treated as uniform properties of the models. We show that the “algorithmic bias” within one such tool— the GPT-3 language model— is instead both fine-grained and demographically correlated, meaning that proper conditioning will cause it to accurately emulate response distributions from a wide variety of human subgroups. We term this property *algorithmic fidelity* and explore its extent in GPT-3. We create “silicon samples” by conditioning the model on thousands of socio-demographic backstories from real human participants in multiple large surveys conducted in the United States. We then compare the silicon and human samples to demonstrate that the information contained in GPT-3 goes far beyond surface similarity. It is nuanced, multifaceted, and reflects the complex interplay between ideas, attitudes, and socio-cultural context that characterize human attitudes. We suggest that language models with sufficient algorithmic fidelity thus constitute a novel and powerful tool to advance understanding of humans and society across a variety of disciplines.

Contents

1 Introduction

2 The GPT-3 Language Model

3 Algorithmic Fidelity

4 Silicon Sampling: Correcting Skewed Marginals

5 Study 1: Free-form Partisan Text

6 Study 2: Vote Prediction

7 Study 3: Closed-ended Questions and Complex Correlations in Human Data

LLMs y proceso de investigación

- Distribución similar de palabras entre el estudio original replicado y el que surge de analizar los datos sintéticos de GPT
- Estos “individuos de silicio” pueden servir
 - para probar diferentes formulaciones de preguntas,
 - clasificar diferentes tipos de medidas,
 - identificar relaciones clave para evaluar más de cerca y elaborar planes de análisis antes de recopilar datos con participantes humanos.




Figure 2. The original Pigeonholing Partisans dataset and the corresponding GPT-3-generated words. Bubble size represents relative frequency of word occurrence; columns represent the ideology of list writers. GPT-3 uses a similar set of words to humans.



¿Qué son las Ciencias Sociales Computacionales?

- **Problemas/preguntas** de investigación más o menos clásicas
- Uso intensivo de algoritmos, cálculos y métodos de predicción
- Combinación / integración de datos diversos
 - diferentes orígenes
 - diferentes procesos de producción
 - diferentes grados de estructuración

¿Qué son las Ciencias Sociales Computacionales?

- Algunas “áreas de incumbencia” (según algunos autores):
 - Análisis de datos
 - extracción automática de contenido / NLP
 - sistemas de información geográfica-social
 - análisis de redes sociales
 - machine learning / métodos cuantitativos
 - Modelos de simulación “generativos”
 - sistemas,
 - microsimulación,
 - MBA, etc.
- **Giro metodológico** en las ciencias sociales

Los datos, los algoritmos y la ciencia social



El problema de los datos

MAS_500 Agglomerados segun tamaño	AGLOMERADO Codigo de Aglomerado	PONDERA Ponderacion	CH03 Relacion de parentesco	CH04 Sexo	CH05 Fecha de nacimiento (dia, mes y año)
N	8	108	2	2	03/06/1990
N	8	108	3	2	29/12/2005
N	8	108	3	1	26/01/2018
N	8	108	1	2	30/03/1978
N	8	108	3	2	20/09/2009
N	8	141	1	1	26/04/1967
N	8	221	1	1	15/03/1955
N	8	221	2	2	25/04/1956
N	8	221	3	2	10/06/1994
N	8	221	1	1	22/07/1944
N	8	221	3	1	23/08/1985
N	8	309	1	1	14/06/1976
N	8	309	2	2	17/06/1978
N	8	309	3	2	20/07/1997
N	8	309	3	1	19/10/2001
N	8	309	1	2	02/01/1967
N	8	309	3	2	29/06/1982
N	8	88	1	1	15/08/1974

14/06/1976

El problema de los datos

ENVÍA TU COMENTARIO Ver legales

Para poder comentar tenés que ingresar con tu usuario de LA NACION.

860 comentarios

INGRESAR

10 personas siguiendo



Esta nota se encuentra cerrada a comentarios.

Más nuevos Más viejos

crisel11 12:55 12/03/2020
Larreta, imrepresentable.

Reportar Compartir

Me gusta

aleman1943 06:42 12/03/2020
"en terapia intensiva "por desaturación"; "Desaturación" de que !!!!! habra sido dehidratación o descubrieron un nuevo "ente" fisiológico en la RA ??

Reportar Compartir

Me gusta

dani20010 18:41 12/03/2020
@aleman1943 se mide la saturación de oxígeno en sangre. Desaturación es la falta de oxigenación, posiblemente por problemas respiratorios.

Reportar Compartir

Josef_Radetzky 06
Tranquilos. Ahora el gobierno manda el Proyecto de Ley de Aborto al Congreso, y se arregla todo.

Reportar Compartir

transilium 05
Cuando todo este pase en unas semanas, se tendrán que hacer responsables los que propagaron el pánico inútilmente causando estragos económicos y sanitarios en todo el planeta.hoy en día estamos mucho mas preparados para el coronavirus que en otras enfermedades del pasado pero peor informados pese a tener datos en directo minuto a minuto.

Reportar Compartir

3 0 0 0 0



<<SimpleCorpus>>
Metadata: corpus specific: 1, document level (indexed): 0
Content: documents: 3

[1] a bailar a bailar | que la orquesta se va | sobre el fino garabato | de un tango nervioso y lerdo | se ira borrando el recuerdo | a bailar a bailar | que la orquesta se va | el ultimo tango perfuma la noche | un tango dulce que dice adios | la frase callada se asoma a los labios | y canta el tango la despedida! | vamos! a bailar! | tal vez no vuelvas a verla nunca | y el ultimo tango perfuma la noche | y este es el tango que dice el adios | a bailar a bailar | que la orquesta se va! | quedara el salon vacio | con un monton de esperanzas | iran camino al olvido | a bailar a bailar | que la orquesta se va!

[2] este tango nacio para bailarse | y asi hamacarse muy suavemente | oigan ustedes este compas... | es muy sencillo bailar el tango | un simple paso despues descanso | la media vuelta la vuelta entera | y siempre junto a la companera | este tango nacio para bailarse | no hay que quedarse mirandolo

[3] nacio en la calle quito | entre boedo y colombres | barrio de tauras de hombres | de timbas y de garitos | mi recuerdo es muy estriado | de prosenio un corralon | modesto fue su blason | y la dulce purretita | se lavaba la carita | en el viejo pileton | amante del varon | soñaba con ser artista | comenzo como corista | hasta llegar a vedette | piernas tipo mistinguetto | cintura bien contorneada | analista envidiada | y un rostro angelical | para que plumas y percal | lucieran como hermanadas | siempre causo sensacion | en cine radio y teatro; | se volco al dos por cuatro | con sentida emocion | triunfo en television | y nadie podra dudar | fue figura consular | en todos los escenarios | recogio aplausos a diario | se llamaba beba bidart

El problema de los datos

Por el propósito de su uso: buscás la comprensión de sentido (?)

1 1 3

La definición más general me parece que sería "una realización de una variable aleatoria discreta cuyo recorrido tiene una cardinalidad pequeña". Lo bueno es que cuando me preguntes cuánto es pequeño te puedo responder "y... es complejo"

Sin releer nada, diría que un dato es una construcción teórico-empírica en el marco de una investigación científica. Es cuali si es narrativo, "natural", a veces inductivo (Burawoy es etnógrafo + tirando a deductivo, x ej.)

Te diría que lo cuali no es el dato sino la metodología. Un mismo dato puede ser cuali o cuanti en función del método de investigación que sigas. Decir "Juan es varón" parece a priori cuali, sin embargo usar ese dato para contar varones y mujeres en un grupo sería cuanti.

para mi es sinonimo de variable categorica, no-ordinal.

Me sumo, aunque difícil responder sin aclarar a que nivel / momento de construcción de dato te referis. Si es en términos generales: dato construido a través de un análisis que tiene a la interpretación por centro.

Lejos de querer ofrecer una respuesta general y rigurosa. Creo que en algunas áreas se usa como grados de precisión. Cualitativo "si esto sube tal cosa baja", semicuantitativo "alrededor de 5" o un "cambio de un orden de magnitud". Cuantitativo, "4.2 con una desviación de 0.3".

No se.. La verdad tendría que pensarlo un poco. En física me da la sensación que unx siempre tiende a querer ponerle número a las cosas poder hacer predicciones (al menos decir si algo es grande o chico respecto a otra cosa o si crece o no, si ta lejos o cerca)...

Una manifestación verbal o escrita, dependiendo de la herramienta utilizada, sobre un fenómeno determinado. Pero ese dato, así en crudo, solo es un relato de una pareció de la realidad social, por eso es fundamental determinar en contexto.

Me quedé pensando. La definición que te dije seguramente "funciona", pero probablemente le falta rigurosidad. Dejame intentar algo más formal. Una VA es una función de Omega a R, no? Sea D: Omega² -> R tal que $D(w_1, w_2) = X(w_1) - X(w_2)$ (sigue)

El problema de los datos



...

La definición más general me parece que sería "una realización de una variable aleatoria discreta cuyo recorrido tiene una cardinalidad pequeña". Lo bueno es que cuando me preguntes cuánto es pequeño te puedo responder "y... es complejo"



...

Lejos de querer ofrecer una respuesta general y rigurosa. Creo que en algunas áreas se usa como grados de precisión. Cualitativo "si esto sube tal cosa baja", semicuantitativo "alrededor de 5" o un "cambio de un orden de magnitud". Cuantitativo, "4.2 con una desviación de 0.3".



...

No se.. . La verdad tendría que pensarlo un poco. En física me da la sensación que unx siempre tiende a querer ponerle número a las cosas poder hacer predicciones (al menos decir si algo es grande o chico respecto a otra cosa o si crece o no, si ta lejos o cerca)...



...

para mi es sinonimo de variable categorica, no-ordinal.



...

Me quedé pensando. La definición que te dije seguramente "funciona", pero probablemente le falta rigurosidad. Dejame intentar algo más formal. Una VA es una función de Ω a $\mathbb{R}$, no? Sea $D: \Omega^2 \rightarrow \mathbb{R}$ tal que $D(w_1, w_2) = X(w_1) - X(w_2)$ (sigue)

El problema de los datos



Por el propósito de su uso: buscás la comprensión de sentido (?)



1



1



3



...

Sin releer nada, diría que un dato es una construcción teórico-empírica en el marco de una investigación científica. Es cuali si es narrativo, "natural", a veces inductivo (Burawoy es etnografo + tirando a deductivo, x ej.)



...

Te diría que lo cuali no es el dato sino la metodología. Un mismo dato puede ser cuali o cuanti en función del método de investigación que sigas. Decir "Juan es varón" parece a priori cuali, sin embargo usar ese dato para contar varones y mujeres en un grupo sería cuanti.



...

Me sumo, aunque difícil responder sin aclarar a que nivel / momento de construcción de dato te referis. Si es en términos generales: dato construido a través de un análisis que tiene a la interpretación por centro.



...

Una manifestación verbal o escrita, dependiendo de la herramienta utilizada, sobre un fenómeno determinado. Pero ese dato, así en crudo, solo es un relato de una pareció de la realidad social, por eso es fundamental determinar en contexto.

El problema de los datos

- Lo “cualitativo”

- Constructivista/
relativista
- Atención al detalle
- Lectura “cercana”
- Escala pequeña
- Fuerte presencia de
lo subjetivo
- Poco escalable
- Centrada en el
“sentido”

- Lo “cuantitativo”

- Positivista (?)
- Importancia de la
generalidad
- Lectura “distante”
- Gran escala
- Intento de
reproducibilidad
- Escalable
- Centrada en la “cantidad”

El problema de los datos

- Lo “cualitativo”

- Constructivista/relativista
- Atención al detalle
- Lectura “cercana”
- Escala pequeña
- Fuerte presencia de lo subjetivo
- Poco escalable
- Centrada en el “sentido”

**Ciencias Sociales
Computacionales
+
Procesamiento de
Lenguaje Natural**

- Lo “cuantitativo”

- Positivista (?)
- Importancia de la generalidad
- Lectura “distante”
- Gran escala
- Intento de reproducibilidad
- Escalable
- Centrada en la “cantidad”

Estructura tripartita (o cuatripartita) del dato (Galtung, 1973)

- Un dato está constituida por la Intersección de tres elementos:
 1. caso (unidad de análisis),
 2. un atributo (variable) y
 3. un valor (categoría) de esa variable
 4. los procesos de construcción de los datos (si le creemos a Samaja, vamos a volver sobre esto mañana)

i	V1	V2	...	Vp
1				
2				
3				
...				
n				

El problema

<<SimpleCorpus>>

Metadata: corpus specific: 1, document level (indexed): 0

Content: documents: 3

[1] a bailar a bailar | que la orquesta se va | sobre el fino garabato | de un tango nervioso y lerdo | se ira borrando el recuerdo | a bailar a bailar | que la orquesta se va | el ultimo tango perfuma la noche | un tango dulce que dice adios | la frase callada se asoma a los labios | y canta el tango la despedida! | vamos! a bailar! | tal vez no vuelvas a verla nunca | y el ultimo tango perfuma la noche | y este es el tango que dice el adios | a bailar a bailar | que la orquesta se va! | quedara el salon vacio | con un monton de esperanzas | que iran camino al olvido | a bailar a bailar | que la orquesta se va!

[2] este tango nacio para bailarse | y asi hamacarse muy suavemente | oigan ustedes este compas... | es muy sencillo bailar el tango | un doble paso despues descanso | la media vuelta la vuelta entera | y siempre junto a la companera | este tango nacio para bailarse | no hay que quedarse mirandolo

[3] nacio en la calle quito | entre boedo y colombres | barrio de tauras de hombres | de timbas y de garitos | mi recuerdo es muy estricto | de proskenio un corralon | modesto fue su blason | y la dulce purretita | se lavaba la carita | en el viejo pileton | amante del varietal | soñaba con ser artista | comenzo como corista | hasta llegar a vedette | piernas tipo mistinguette | cintura bien contorneada | anatomia envidiada | y un rostro angelical | para que plumas y percal | lucieran como hermanadas | siempre cause sensacion | en cine radio y teatro; | se volco al dos por cuatro | con sentida emocion | triunfo en television | y nadie podra dudar | fue figura consular | en todos los escenarios | recogio aplausos a diario | se llamaba beba bidart


El problema

MAS_500 Aglomerados segun tamaño	AGLOMERADO Codigo de Aglomerado	PONDERA Ponderacion	CH03 Relacion de parentesco	CH04 Sexo	CH05 Fecha de nacimiento (dia, mes y año)
N	8	108	2	2	03/06/1990
N	8	108	3	2	29/12/2005
N	8	108	3	1	26/01/2018
N	8	108	1	2	30/03/1978
N	8	108	3	2	20/09/2009
N	8	141	1	1	26/04/1967
N	8	221	1	1	15/03/1955
N	8	221	2	2	25/04/1956
N	8	221	3	2	10/06/1994
N	8	221	1	1	22/07/1944
N	8	221	3	1	23/08/1985
N	8	309	1	1	14/06/1976
N	8	309	2	2	17/06/1978
N	8	309	3	2	20/07/1997
N	8	309	3	1	19/10/2001
N	8	309	1	2	02/01/1967
N	8	309	3	2	29/06/1982
N	8	88	1	1	15/08/1974

14/06/1976

MÁS COMENTADAS

- 1 El Gobierno sacará por ENL el congelamiento de salarios y créditos hipotecarios
- 2 Coronavirus: Alfredo Casero entró contra Marcelo Trullé y Diego Brancatelli
- 3 "Ya nos abandonan, no somos unos chetos", la frustración de los argentinos varados
- 4 Coronavirus: sus 3.022 nuevos casos, el más alto de la semana en Italia
- 5 La hora de pensar si hay una alternativa



[1] a bailar a bailar | que la orquesta se va | sobre el fino garabato | de un tango nervioso y lerdo | se ira borrando el recuerdo | a bailar a bailar | que la orquesta se va | el ultimo tango perfuma la noche | un tango dulce que dice adios | la frase callada se asoma a los labios | y canta el tango la despedida | vamos! a bailar! | tal vez no vuelvas a verla nunca | y el ultimo tango perfuma la noche | y este es el tango que dice el adios | a bailar a bailar | que la orquesta se va! | quedara el salon vacio | con un monton de esperanzas | que iran camino al olvido | a bailar a bailar | que la orquesta se va!

[3] nacio en la callequito | entre bosco y colombres | barrio de tauras de hombres | de timbas y de garitos | mi recuerdo es muy estirico
 de prosencio un corralon | mostro bese su blason | y la dulce purrreita | se lavaba la carita | en el viejo piloton | anante del varieton
 e | sonaba con ser artista | comenzo como corista | hasta llegar a vedette | piamas tipo mistingueito | cintura bien contereñada | anatomia
 la envidiada | y un rostro angelical | para que plumas y percal | lucieran como hermanadas | siempre causo sensacion | en cine radio y teatro
 tro; se volco al dos por cuatro | con sentida emociion | triunfo en television | y nadie podra dudar | que figura consular | en todos los
 escenarior | recogio aplausos a diario | se llamaba beba bidart

MAS_500	AGLOMERADO	PONDERA	CH03	CH04	CH05
Agglomerados segun tamaño	Codigo de Aglomerado	Ponderacion	Relacion de parentesco	Sexo	Fecha de nacimiento (dia, mes y año)
N		8	108	2	03/06/1990
N		8	108	3	29/12/2005
N		8	108	3	12/01/2018
N		8	108	1	30/03/1978
N		8	108	3	20/09/2009
N		8	141	1	12/04/1967
N		8	221	1	15/03/1955
N		8	221	2	25/04/1956
N		8	221	3	10/06/1994
N		8	221	1	22/07/1944
N		8	221	3	13/08/1985
N		8	309	1	14/06/1976
N		8	309	2	17/06/1978
N		8	309	3	20/07/1997
N		8	309	3	19/10/2001
N		8	309	1	02/01/1967
N		8	309	3	29/06/1982
N		8	88	1	15/08/1974




Grado de estructuración

factor~data. Ciencias Sociales Computacionales en la Escuela IDAES.

Es un espacio de investigación y formación nacido en 2020, que busca fomentar el uso de herramientas computacionales aplicadas a la resolución de preguntas de estudio tradicionales.

Email: factor.data.idaes@gmail.com

CONTACT



Líneas de trabajo

- Investigación Aplicada
 - Cursos de posgrado
 - Track orientado en métodos cuantitativos y ciencias sociales computacionales
 - Diploma en Ciencias Sociales Computacionales y Humanidades Digitales
- **Formación y pedagogía**
- Investigación Básica


Líneas de trabajo

- Investigación Aplicada
 - Territorio, espacio y desigualdad
- Formación y pedagogía
 - Procesamiento de lenguaje natural (NLP) aplicado a las ciencias sociales
- Investigación Básica


Modos de expansión de la frontera agraria

- Obtener un mapa con la mayor resolución posible que permita identificar en el territorio argentino
 - zonas de expansión de frontera agraria recientes
 - zonas de agricultura “consolidada”
 - zonas de expansión de urbanización recientes
- El mapa debe abarcar la mayor cantidad posible del territorio argentino


Datos utilizados




Datos utilizados



1992	1999	2006	2013	2020
Agr	Agr	Agr	Agr	Agr
For	For	Agr	Agr	Agr
For	For	For	For	For
For	For	Urb	Urb	Urb




Monte Quemado (Santiago del Estero)
1992



Monte Quemado (Santiago del Estero)
2020



Monte Quemado (Santiago del Estero)
Tipo de uso del suelo



Tipo de trayectoria LUCC

- Expansión frontera agraria
- Expansión frontera agraria (arbustal)
- Agricultura estable
- Bosque estable
- Arbustal estable
- Urbaniz. estable
- Hacia urbanización

Modos de expansión de la frontera agraria - Algunos resultados

Geograficando

Revistas de la FaHCE

Actual

Archivos

Avisos

Acerca de ▾

[Inicio](#) / [Archivos](#) / [Vol. 19 Núm. 1 \(2023\)](#) / [Artículos](#)

Analizando trayectorias de uso del suelo. Una propuesta de clusterización

HTML

PDF

EPUB

Publicado: May 2,
2023

DOI:
<https://doi.org/10.24215/2346898Xe130>

Palabras clave:
Uso del suelo
Cambio de cobertura
Frontera agraria
Análisis de secuencias

German Rosati

Escuela Interdisciplinaria de Altos Estudios Sociales (UNSAM-CONICET), Universidad Nacional de San Martín / Programa de Investigaciones sobre el Movimiento de la Sociedad Argentina, Argentina

<https://orcid.org/0000-0002-9775-0435>


Resumen

El trabajo presenta una alternativa metodológica para analizar trayectorias de uso de suelo. Toma como caso de estudio y prototipo un análisis de los cambios en el uso del suelo a un nivel general de Argentina (región pampeana, NEA, NOA y Cuyo). El objetivo es obtener un mapa con la mayor resolución posible que permita detectar las siguientes situaciones: 1) zonas recientes de expansión de frontera agraria; 2) zonas de agricultura "consolidada" y 3) zonas recientes de expansión de urbanización. Este trabajo se centra especialmente en el desarrollo de la metodología aplicada y en un primer intento de validación de la misma. A partir de datos de la Agencia Espacial Europea (ESA) vinculados a la "Climate Change Initiative-Land" (ESA-CCI-LC) del período 1992-2020 se genera una clusterización de trayectorias de uso del suelo mediante distancias de edición (utilizadas para el análisis de secuencias). Se obtuvieron 29 tipos de trayectorias a nivel píxel validadas por análisis visuales, con performance aceptable para la detección de diferentes trayectorias.

<https://www.geograficando.fahce.unlp.edu.ar/article/view/geoe130>

Líneas de trabajo

- Investigación Aplicada
 - Territorio, espacio y desigualdad
- Formación y pedagogía
 - Procesamiento de lenguaje natural (NLP) aplicado a las ciencias sociales
- Investigación Básica



“Mucha gente ha leído más y mejor que yo, por supuesto, pero eso tampoco basta: aquí hablamos de cientos de lenguas y literaturas. Todo indica que leer ‘más’ no es la solución. En especial, porque hemos comenzado a descubrir (...) la enormidad de lo no leído (...) pero el punto es que existen treinta mil novelas británicas del siglo XIX o cuarenta o cincuenta, sesenta mil: nadie lo sabe a ciencia cierta, nadie las ha leído, nadie las leerá. Y, además, hay novelas francesas, chinas, argentinas, estadounidenses.

Leer ‘más’ siempre es bueno, pero no es la solución” (p. 59)

Topic Modeling

Malena canta el tango

Garúa, solo y triste por la acera

Mi barrio reo

	acera	barrio	canta	garúa	reo	tango	triste
C1	0	0	1	0	0	1	0
C2	1	0	0	1	0	0	1
C3	0	1	0	0	1	0	0

Matriz de Frecuencia de términos

	acera	barrio	canta	garúa	reo	tango	triste
T1	0.9	0.8	0.05	0.9	0.1	1	0.01
T2	0.01	0.02	0.9	0.02	0.01	0.9	0.03



Matriz de Términos x Tópicos

Matriz de Documentos x Tópicos

	T1: Barrio	T2: Tango
C1	0.01	0.99
C2	0.95	0.05
C3	0.99	0.01

Los temas de la música popular

- Problema: analizar los temas de letras de la música popular
- Enfoque “hermenéutico”
- Lecturas canónicas/cercanas
- Temas comunes: representaciones de género, figuras del “guapo”, representaciones del arrabal, etc.
- Tema poco estudiado en el rock



Datos

- Scrap de dos sitios
- Corpus:
 - 5.700 letras tango
 - 16.000 letras rock

Afiches
Tango
Música: Atilio Stampone
Letra: Homero Expósito

Me gusta 115 Compartir Twitter

Música Letra Video Versiones

Cruel en el cartel,
la propaganda manda cruel en el cartel,
y en el fetiche de un afiche de papel
se vende la ilusión,
se rifa el corazón...
Y apareces tú
vendiendo el último jirón de juventud,
cargándome otra vez la cruz.
¡Cruel en el cartel, te ríes, corazón!
¡Dan ganas de balearse en un rincón!

Ya da la noche a la cancel
su piel de ojera...
Ya moja el aire su pincel
y hace con él la primavera...
¿Pero qué?
si están tus cosas pero tú no estás,
porque eres algo para todos,
como un desnudo de vidriera...
¡Luché a tu lado, para ti,
por Dios, y te perdí!

Rock.com.ar
el sitio del rock en la Argentina

1 DE NOVIEMBRE DE 2021 PRINCIPAL ACTUALIDAD ENCICLOPEDIA

A B C D E F G H I J K L M N O P Q

SHARE

Divididos

SUMARIO BIO COMPLETA DISCOGRAFÍA FOTOS LETRAS

Paisano de Hurlingham

Paisano de Hurlingham
poda neblina
moneda o botón
ciego bilingüe
paso morales fue
sin la opalina
de Retiro a Pilar
busca el chanco al chabon.
Sapo explota en San Martín
los domingos a las diez
sable recto en la estación
berretin de mayor.
Canilla en el anden
gotea noticias
te grita el titular
mentiras sin picar.
Abejas con ombu
viajando en el panal

12 temas detectados

01 Imágenes climáticas

después estrella
nombre sombra tiempo
espera viento final
sueño sol luna tarde
vez cielo adiós
ojos noche piel
luz voz dos
manos mar gris
sueños calle soledad
silencios sombras
camino

05 Campo y gauchesca

bajo muerto
gloria dios juan pronto
hizo rancho allí
china dio dió habia vio
dije pobre tierra tenia criollo
grito don iba patria
pampa gaucho huella perro
largo llevo después
camino blanca

09 Emociones negativas

mujer penas
pobre carino cruel
vivir querer mal
alma dolor triste
solo vida hoy
dia amor vez
corazon mia
quiero pena
lado nunca siento
siempre puedo ojos

02 Ciudad, imágenes urbanas

libre historia
nueva siempre pueblo
esquina algún
quiere calles aires
sur ali pais
plaza cada rio vino
libertad toda lugar
luzes buenos
abrazo mil
gusta ciudad hijos
encuentro gente

06 Tango y arrabal

porteño cantando
gardel emocion notas
cancion arrabal triste
compas canto cantor
cantar barrio viejo
bajo baile
alma paris
voz
milonga bailar
bandoneon tangos
canta corazon hace
guitarra muchachos
percal

10 Candombe

sueño morena
charol ropa
seda coro niño candombe
sangre negra loca
saben risa negro blanco
loco hace cuerpo
negros pelo maria
dio carnaval hacen
mismo agua pasar
mundo

03 Misc

gitar cruce
triste alguien fuerte
medio mano oscura
aun dice momento dia
mia pues toda fondo copa
van historia voy razon
mundo sigue loco aqui
cabeza entero cara
almas venga

07 Tiempo, recuerdos

aquellos viejos
noches entonces
aquella dias
recuerdos queda
cosas años
volver tiempo
vida hoy
están vieja
igual ahora
recuerdo nuevo
amigos pasado lejos
barrio parece horas
siempre

11 Misc y familia

grito dinero
domingo alla niños
veo casi lado coraje
alegría dia hizo pie
hora toda
diga adentro dicho rato
alcanza sangre pues vieja
cerca deja queda

04 Emociones positivas

soñar toda
noches amores canto
flores pasión linda
dulce ojos labios
corazon feliz
amor sol
luz flor alma
ilusion cancion
emocion mujer junto
sueño ternura querer


08 Misc

cosas
dicen dios verdad bien
amigo hombre nunca
puede vida aunque
ver mundo vivir
dos ser nadie
siempre mano
sabe voy aqui mejor
sera mismo gente
vamos mañana
andar hacer

12 Misc y lunfardo

bronca pinta haces
pal sabes bulin
hace tenes suerte
hoy vassos ves anda
pibe buen
pobre vos che
mina bien gran hecho
bacan bien gran cara
hermano queres
después ver
juego

Composición de tópicos de 4 tangos



JORGE LUIS
BORGES

El tango


Cuatro conferencias

SUDAMERICANA

“El tango, como hemos visto, empezó, surge de la milonga, y es al principio un baile valeroso y feliz. Y luego, el tango va languideciendo y entristeciéndose...”

III Conferencia, p.80-81

Evolución de los tópicos, 1900-2010 (suavizado GAM)



Los temas de la música popular - Algunos resultados

Núm. 23 (12)

Procesamiento de Lenguaje Natural aplicado a las ciencias sociales. Detección de tópicos en letras de tango

ARTÍCULOS

Publicado 2022-04-12

Germán Rosati^{*}

Resumen

En este artículo, se presenta una aplicación de una técnica de Procesamiento de Lenguaje Natural (modelado de tópicos) sobre un corpus de letras de tango. Introduce un flujo de trabajo posible para el análisis textual computacional y en una técnica específica para la detección de tópicos: Latent Dirichlet Allocation (LDA). Se trabajará sobre un corpus de 5.617 letras buscando detectar de forma semiautomática sus temas. Los tópicos detectados abarcan desde imágenes de la ciudad, sobre el tango mismo, sobre emociones negativas y positivas, etc. Se analiza su evolución temporal y se muestra el cambio relativo de los tópicos en las letras de tango. También se valida el modelo analizando la composición de tópicos de algunos tangos canónicos. El trabajo busca ilustrar las potencialidades que estas técnicas tienen para el análisis de datos textuales en ciencias sociales: su escalabilidad y sus posibilidades de replicabilidad. Se marcan, finalmente, algunas limitaciones de este enfoque.

PDF




Palabras clave

procesamiento de lenguaje natural
tango
modelado de tópicos
web scraping
minería de texto


http://www.relmis.com.ar/ojs/index.php/relmis/article/view/procesamiento_lenguaje_natural

Discursos de odio y violencia en redes sociales


- Analizar patrones en la recepción y emisión de discursos violentos/de odio y su relación con género y orientación política
- API Twitter + Transformers pre-entrenados
- Laia Domenech (factor~data -EIDAES-UNSAM)
- Juan Manuel Pérez (CONICET / LIIA-UBA)
- Diego Kozlowski (École de bibliothéconomie et des sciences de l'information, Université de Montréal)




Discursos de odio y violencia en redes sociales




Proportion of hateful tweets received and emitted by political figures, and weighted average by total number of tweets of each political figure.



Proportion of tweets that contain a specific type of hate speech over the total of mentions, by gender.



Total number of tweets emitted by users' political orientations and proportion of hateful tweets by gender of politicians.



saberes
Revista de ciencias económicas y estadísticas

[Actual](#) [Contacto](#) [Archivos](#) [Avisos](#) [Acerca de ▾](#) [Estadísticas](#)

[Inicio](#) / [Archivos](#) / [Vol. 14 Núm. 2 \(2022\)](#) / [Artículos](#)

Adriana Chazarreta

Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET), Argentina y
Escuela Interdisciplinaria de Altos Estudios Sociales (EIDAES) de la Universidad
Nacional de San Martín (UNSAM), Argentina
<https://orcid.org/0000-0002-4737-9578>

DOI: <https://doi.org/10.35305/s.v14i2.224>

Palabras clave: Gerente y patrón, Industria manufacturera, Análisis de correspondencias múltiples

Resumen

El objetivo general es evaluar cuál es el grado en que se ha desarrollado la separación propiedad-control del capital en la actividad industrial de Argentina en la última década. Se utiliza como indicador proxy de este proceso el tipo de estructuras de organización o gestión de la empresa. Los objetivos específicos son construir un índice -a partir del Análisis de Correspondencias Múltiples (ACM)- que permita clasificar a las empresas según el grado de separación de la propiedad y la dirección de las mismas y comparar el alcance en empresas con diferentes características. Se trabaja con la Encuesta Nacional de Dinámica del Empleo e Innovación (ENDEI) 2010-2012 realizada por el Ministerio de Ciencia, Tecnología e Innovación Productiva junto al Ministerio de Trabajo, Empleo y Seguridad Social (MTEySS) de Argentina. En su análisis, empresas grandes, no familiares, con alta proporción de capital internacional y pertenecientes al grupo de servicios, con más de un lugar productivo o dedicadas a actividades como del sector farmacéutico o químico presentan en mayor porcentaje valores altos respecto al grado de organización de la gestión de las empresas, por tanto, valores más cercanos a niveles altos de separación.

Citas



Una publicación del Grupo de Estudios sobre Comunicación, Política y Seguridad
del Instituto de Investigaciones Gino Germani (UBA)

Contributions from natural language processing to increase scalability in studies on topics of digital security news

Florencia Nathalia Piñeyrúa

Escuela Interdisciplinaria de Altos Estudios Sociales (IDAES). Universidad Nacional de San Martín (Argentina).

Correo: pinievrua@gmail.com

Fecha de recepción: 15 de junio de 2021

Fecha de aceptación: 17 de diciembre de 2021

Resumen:

Este trabajo explora la aplicación de técnicas de procesamiento de lenguaje natural y *web scraping* para el estudio de contenido de noticias digitales a gran escala. Para ello, trabajamos con datos primarios contruidos a partir de la técnica de *web scraping* utilizando como soporte empírico las noticias publicadas desde julio a septiembre 2019 en los portales *Clarín*, *La Nación*, *Infobae*, *Página 12*, *Télam*, *Perfil*, *Crónica* y *Minuto Uno*. En el procesamiento del corpus empleamos la técnica de procesamiento de lenguaje natural para la detección de tópicos con la implementación del método *Latent Dirichlet Allocation* (LDA). Los resultados muestran que los principales tópicos de la agenda mediática digital durante el contexto de las elecciones Primarias Abiertas Simultáneas y Obligatorias son las elecciones, los espectáculos, el deporte, la seguridad y la política.

Mapeo de desmontes en bosques nativos de Argentina. Propuesta de mejoras en el Sistema de Alerta Temprana de Deforestación.

Laia Domenech

Los resultados

Probamos tres modelos estadísticos distintos para predecir la etiqueta de clasificación. El modelo que mejor funcionó fue *Random Forest*, que capturó el 91% de los puntos deforestados, y clasificó correctamente el 87% de los puntos deforestados.

Estos modelos también funcionan bien para predecir deforestación según las regiones de protección de bosques nativos definidas por las OTBN provinciales. Podemos observar que si bien hay un sesgo hacia la detección de falsos positivos (es decir, a detectar puntos “de más”), la distribución de puntos predichos como deforestados se distribuyen de manera similar que los puntos reales entre las categorías de conservación.




Gráfico 1. QTNB de los puntos deforestados

Para cerrar... otras grietas

- Cualitativo / Cuantitativo
- Teoría / Empiria
- Comprension, Explicación / Predicción
- Ciencias Idiográficas / Ciencias Nomotéticas
- La irrepetible levedad del campo / La investigación reproducible
- Especialización vs. Interdisciplina

¿Preguntas?



[@FactorData](#)



<https://factor-data.netlify.app/>



<https://medium.com/factor-data>



<https://gefero.github.io/>



german.rosati@gmail.com