

19 de agosto de 2026

Detección de discursos de odio

Natalia Debandi

ndebandi@unsam.edu.ar

CONICET · CIAI-UNSAM



Pawel Kuczynski

Monitor de Discursos de Odio en redes sociales

Centro Interdisciplinario de Inteligencia Artificial — UNSAM

Coordinación

Micaela Cuesta (LEDA / LICH)

Natalia Debandi (CIAI-ECyT / CONICET)

Equipo

Sol Gui · Pablo Villarreal (LEDA)

Ana Paula Penchaszadeh (NEM-EIDAES / CONICET)

Belen Quiñones (LCD-CIAI) · Gianni Bevilaqua (LCD-CIAI) - Bautista Turri (LCD-UNSAM)

Objetivo

Desarrollar un mecanismo permanente de recolección, clasificación y visualización de discursos de odio en redes sociales en Argentina.

Categorías

Xenofobia · Racismo · Misoginia

Clasismo · Antisemitismo

Equipos

(2) Preguntas disciplinares distintas:

- a) Comparar los nuevos modelos de lenguaje (GPT) con clasificadores clásicos como BETO (ciencias de datos)
- b) Analizar en particular las representaciones sociales y xenofobia sobre migrantes en pandemia (ciencias sociales)

+

(1) Preguntas disciplinares distintas:

- a) ¿Cuanto mejora el contexto el performance de un clasificador (computación)
- b) Peso y forma de la discriminación y el odio en redes sociales durante la pandemia (ciencias sociales)
- c) Posibilidades de la big data y las técnicas de ciencias de datos (2020) para aportar al estudio de las marginaciones sociales (metodología)

2024

Detección de discursos discriminatorios y de odio en redes sociales en Argentina

GPT

2025

Xenofobia en redes sociales: pandemia y DNU 70/2017

CIAI-UNSAM

2026-2027

Monitor de Discursos de Odio

CIAI-UNSAM · LEDA

Equipos

(2) Preguntas disciplinares distintas:

- a) Diseñar un mecanismo permanente de detección de odio/discriminación robusto y seguro
- b) Monitoreo permanente de discriminación y odio con categorías específicas (ciencias sociales)


Estudio vs. monitoreo permanente

	ESTUDIO ESPECÍFICO	MONITOREO PERMANENTE
Protección de datos personales	Se resuelve una vez, antes de publicar	Exige arquitectura, flujo y gobernanza permanentes
Profundidad	Puede indagar en detalle un aspecto acotado	Llega a todo, pero no permite indagar en profundidad de forma sistemática
Vigencia del instrumento	El modelo se elige y se congela	Se degrada: exige reentrenamiento y mecanismos de actualización
Temporalidad	Una foto de un período cerrado	Una línea continua, que permite estudiar de forma permanente

DEFINICIONES CENTRALES

- (1) ¿Qué es odio? ¿cómo lo operacionalizamos?
- (2) ¿Qué representatividad tiene lo que medimos?
¿cuánto del discurso público es eso?

Un pipeline lineal de clasificación



¿Qué es discurso de odio?

DEFINIR

Definiciones de odio

ONU (2019)

"cualquier forma de comunicación de palabra, por escrito o a través del comportamiento, que sea un ataque o utilice lenguaje peyorativo o discriminatorio en relación con una persona o un grupo sobre la base de quiénes son [...] en razón de su religión, origen étnico, nacionalidad, raza, color, ascendencia, género u otro factor de identidad."

Naciones Unidas (2019). Estrategia y Plan de Acción de las Naciones Unidas para la Lucha contra el Discurso de Odio. Nueva York, mayo de 2019, p.

Abramovich (2021)

"la incitación directa a la violencia, lo que comprende la violencia física, la amenaza a la vida y a la integridad física, y también la creación de un clima grave de hostigamiento y persecución directa de un grupo social determinado."

Abramovich, V. (2021). "Dilemas jurídicos en la restricción de los discursos de odio". En V. Abramovich, M. J. Guembe y M. Capurro Robles (coords.), *El límite democrático de las expresiones de odio. Principios constitucionales, modelos regulatorios y políticas públicas* (pp. 17-58). Buenos Aires: Teseo / UNLa..

Torres, N. y Taricco, V. (2021). "Los discursos de odio como amenaza a los derechos humanos". En V. Abramovich, M. J. Guembe y M. Capurro Robles (coords.), *El límite democrático de las expresiones de odio* (pp. 59-96). Buenos Aires: Teseo / UNLa. **Los tres tipos, en pp. 70-71**

Tipo	Qué es	Qué daña
Discurso de odio (en singular)	"prácticas enunciativas de incitación a cometer actos violentos"	La vida y la seguridad
Discursos discriminatorios	"pretenden que una persona o un grupo de personas sean excluidos, segregados o imposibilitados de ejercer sus derechos"	La "dignidad ciudadana": el derecho a ejercer libremente sus derechos, su ciudadanía
Discurso hostigador	"práctica discursiva sistemática realizada con la intención de impedir o limitar el uso de la palabra en el espacio público"	La libertad de expresión de la víctima, "a través del acoso o el amedrentamiento"

Discurso de odio

¿Cómo operacionalizamos la definición de discurso de odio?

Ejercicio

¿Es discurso de odio? **Sí o No**

Diez comentarios reales del corpus PIUBAMAS — respuestas a noticias en Twitter, marzo 2020 a mayo 2021.

@LANACION · 29 mar 2020

Coronavirus: afirman que volvió la venta de carne de murciélagos en China

USUARIO_7F3A1C42

“Muerte a China,, chinos hijos de mil putassss”

¿Es discurso de odio? Sí / No

@maquialifracó · 5 mar 2021 · 6.246 retuits

Tweet propio, en el debate por la derogación del DNU 70/2017

@maquialifracó

“Argentina, el país que exporta jóvenes profesionales e importa delincuentes.”

¿Es discurso de odio? Sí / No

@larepublica_pe · 6 mar 2021

Residentes extranjeros serán vacunados contra la COVID-19, afirmó Óscar Ugarte

USUARIO_2B9E7D10

“pobres extranjeros”

¿Es discurso de odio? Sí / No

@LANACION · 2 ago 2020

González Oro, harto de la cuarentena: «El día que se pueda me voy a Uruguay»

USUARIO_A41C8F63

“Vos los VOTASTE NEGRO PERONCHO ahora
bancatela JAJA KISCHNERISTA 👍 🤡 🤡”

¿Es discurso de odio? Sí / No

@wekaweko1 · 5 mar 2021

¿Qué lógica tiene dejar entrar extranjeros con antecedentes penales? 🧐

USUARIO_5D02A9B7

“Que logica tiene dejar entrar extranjeros? Que se peguen un tour y rajen.”

¿Es discurso de odio? Sí / No

@LANACION · 23 jun 2020

China: comenzó el tradicional Festival de carne de perro a pesar de la pandemia

USUARIO_C8B41E05

“Chinos hdp.        ”

¿Es discurso de odio? Sí / No

@MiguelPichetto · 5 mar 2021 · 4.971 retuits

Senador nacional. Tweet propio, en el debate por la derogación del DNU 70/2017

@MiguelPichetto

“No hay que permitir el ingreso de extranjeros con antecedentes penales a la Argentina.”

¿Es discurso de odio? **Sí / No**

@infobae · 16 jun 2020

Un diputado chileno propuso trasladar a enfermos de coronavirus a la Argentina

USUARIO_1E7F35CA

“Chile ayudó a Inglaterra en la guerra de Malvinas, en perjuicio de Argentina. Pero los argentinos somos buena gente y para nada rencorosos. Por eso les permitiremos traer a sus enfermos a territorio nacional. El lugar: nuestras amadas Islas Malvinas.”

¿Es discurso de odio? Sí / No

@wekaweko1 · 5 mar 2021

¿Qué lógica tiene dejar entrar extranjeros con antecedentes penales? 🧐

USUARIO_9A3C60D8

“La lógica q tiene un delincuente defendiendo y justificando a otro delincuente, o sea, entre delincuentes se entienden!!!”

¿Es discurso de odio? Sí / No

@wekaweko1 · 5 mar 2021

¿Qué lógica tiene dejar entrar extranjeros con antecedentes penales? 🧐

USUARIO_63F0B2A4

“Solo la lógica de un gobierno que no tiene lógica. Diría un pelotudo por ahí... viva Perón carajo... una mierda.”

¿Es discurso de odio? Sí / No

Resultados

Tweet	ODIO	No ODIO
01 "Muerte a China, chinos hijos de mil putas"		
02 "Argentina, el país que exporta jóvenes profesionales e importa delincuentes"		
03 "pobres extranjeros"		
04 "Vos los VOTASTE NEGRO PERONCHO ahora bancatela"		
05 "¿Qué lógica tiene dejar entrar extranjeros? Que se peguen un tour y rajen"		
06 "Chinos hdp"		
07 "No hay que permitir el ingreso de extranjeros con antecedentes penales"		
08 "Chile ayudó a Inglaterra... El lugar: nuestras amadas Islas Malvinas"		
09 "Entre delincuentes se entienden"		
10 "Un gobierno que no tiene lógica... viva Perón carajo... una mierda"		

Comparación de la sala con los clasificadores

Ítem	Comentario	Sala % odio	pysentimiento (0,50)	BETO PIUBA (0,45)	¿Coinciden?
01	Muerte a China, chinos hijos de mil putas		hateful 0,61	RACISM · CALLS	sí
02	Argentina exporta profesionales e importa delincuentes		hateful 0,60	sin etiqueta	NO
03	pobres extranjeros		sin etiqueta	RACISM	NO
04	Vos los VOTASTE NEGRO PERONCHO		hateful 0,76 · aggressive 0,72	RACISM	sí
05	Que se peguen un tour y rajen		hateful 0,92 · aggressive 0,58	sin etiqueta	NO
06	Chinos hdp		hateful 0,51	RACISM	sí
07	No permitir el ingreso de extranjeros con antecedentes		hateful 0,74	sin etiqueta	NO
08	Chile ayudó a Inglaterra... nuestras amadas Islas Malvinas		hateful 0,79	RACISM	sí
09	Entre delincuentes se entienden		sin etiqueta	sin etiqueta	sí
10	Un gobierno que no tiene lógica... viva Perón carajo		sin etiqueta	sin etiqueta	sí

El acuerdo de la sala . Alpha de Krippendorff

Alpha de Krippendorff

0, _ _

Los seis anotadores de PIUBAMAS

0,579

0,667 es el piso que sugiere
Krippendorff para conclusiones

Medidas de acuerdo

Tabla de contingencia

	BETO SÍ	BETO NO
py sentimiento SÍ	4	3
py sentimiento NO	1	2

Sobre el corpus del monitor

n = 1.423.897 publicaciones

**acuerdo observado 88,3 % · kappa
0,228**

Coincidencia

Coinciden SÍ sobre el total

40 %

Acuerdo simple

Coinciden si + no sobre el total

60 %

Índice de Jaccard

$4 \div (4+3+1)$ Intersección sobre unión, calculada sólo sobre la clase positiva

0,50

Kappa de Cohen

acuerdo corregido por azar, dos anotadores

0,20

Alpha de Krippendorff


ídem, para cualquier número de anotadores

0,21

Modelos y medición

CONSTRUCTO	CRITERIO: qué cuenta como positivo	CLASIFICADOR	MATERIALES SUBYACENTES
Toxicidad	Un comentario grosero, irrespetuoso o irrazonable que probablemente haga que alguien abandone la conversación	Perspective API Jigsaw / Google, 2017	Comentarios de Wikipedia y de medios asociados, etiquetados por crowdsourcing
Ofensividad	Lenguaje no aceptable —insultos, amenazas, groserías— o una ofensa dirigida, velada o directa. Incluye la puteada sin destinatario	OffensEval cardiffnlp/twitter-roberta-base-offensive	OLID / OffensEval, SemEval 2019. Tres capas: ofensivo, dirigido, tipo de blanco
Odio	¿Es odioso? Y dos sub-etiquetas: ¿dirigido a un individuo?, ¿es agresivo? La etiqueta no dice contra quién	pysentimiento (librería) modelo robertuito-hate-speech	HatEval, SemEval 2019 T5, subtask B. Anotado sólo sobre inmigrantes y mujeres
Discriminación y odio	Estigmatización por ocho características protegidas, más una etiqueta aparte de llamado a la acción violenta	BETO (modelo) beto-contextualized-hate-speech	Corpus rioplatense anotado por el proyecto PIUBAMAS (UBA). Marco: INADI 2005 + CADH, PIDCP, CERD
Intensidad como continuo	Diez ítems ordinales —respeto, insulto, humillación, deshumanización, violencia, genocidio— combinados en una escala continua	Modelos de UC Berkeley	Kennedy et al. 2020. 39.565 comentarios, 7.912 anotadores, medición Rasch

PROYECTO PIUBAMAS




- | | |
|---|---|
| <ul style="list-style-type: none">• apariencia• clasismo• criminalidad• Discapacidad• LGBTI | <ul style="list-style-type: none">• mujeres• racismo• discriminación• política |
|---|---|

Seis anotadores, dos meses, 450 horas. Alpha de Krippendorff: 0,579.

RECOLECCIÓN





Newspapers	Tweets (OT)	Comments (RP)
infobae	92.194	1.582.932
clarincom	62.013	1.406.382
LANACION	48.318	1.484.861
cronica	47.841	196.361
pagina12	27.920	215.471
perfilcom	19.762	152.435
Total	298.048	5.038.442

Spritzer Twitter API

Piubamas

Periodo: marzo 2020 - mayo 2021

Palabras claves/filtros de noticias: COVID, Pandemia, Covid-19, cuarentena..

**¿Qué representatividad tienen
nuestros datos? ¿Cómo diseñar la
muestra?**

**¿qué universo estamos
estudiando?**

Diseño muestral del monitor: fuentes

Tendencias de Argentina

DIARIA · 23:05 hs

- Tweets de la sección "Tendencias" de X en Argentina, con todos sus comentarios
- Captura el debate espontáneo del día
- X filtra por región: da relevancia local sin geolocalización explícita
- Sólo se pueden extraer el día en curso — no hay consulta retrospectiva

Medios de comunicación

SEMANAL · sábados 10:05 hs

- 10 medios argentinos de distintas líneas editoriales
- Se extrae con una semana de diferencia: los comentarios tardan en acumularse
- Permite rastrear qué novedades disparan discurso de odio
- Es el diseño de PIUBAMAS, ahora como una fuente entre dos

Esfera pública ¿Cómo definirla?¿cuanto ocupan los medios?

¿De dónde viene el odio? (HATEFUL·BETO — 104,002 casos)
Mirando SOLO medios se pierde el 90% del odio



— tendencias: 89.7% del odio (93,252)
— medios: 10.3% del odio (10,750)

7,4 %

del volumen total viene de medios

10,3 %

del odio detectado está en medios

10,2 % vs 7,1 %

tasa de odio: medios vs tendencias

**Sólo con medios veríamos el 7 % de la conversación
y nos perderíamos el 90 % del odio capturado.**

Tendencias



Home



Explore



Notifications



Follow



Chat



Grok



History



Profile



More

Post

Q Search



For You

Trending

News

Sports

Entertainment

Global Trending

The most popular posts

Explore

1 • Trending in Argentina

San Martín

2 • Only on X • Trending

LUANA AL 9009

Trending with [Juana](#)

3 • Trending in Argentina

Moria

4 • Only on X • Trending

Padre de la Patria

5 • Trending in Argentina

Vicuña

← Ar

← Countries

Popul:

Global

US United States

DZ Algeria

AR Argentina

AU Australia

Cómo se recolecta

```
# 02_recoleccion_tendencias.py

from playwright.sync_api import sync_playwright

with sync_playwright() as p:
    nav = p.chromium.launch(headless=True)

    ctx = nav.new_context()
    ctx.add_cookies(cookies_sesion)    # .env

    pg = ctx.new_page()
    pg.goto(URL_TENDENCIAS)

    for _ in range(N_SCROLLS):
        pg.mouse.wheel(0, 3000)
        pg.wait_for_timeout(
            random.uniform(800, 2200))

    tweets = pg.query_selector_all(
        'article[data-testid="tweet"]')
```

No hay API

X cerró el acceso para investigación en 2023. Se automatiza un navegador real.

Cookies de sesión

AUTH_TOKEN, CT0, GUEST_ID... en un .env que no se versiona. Si X redirige al login, el script se corta y avisa por Telegram.

Scroll y espera al azar

Delays aleatorios entre pedidos para no ser detectado como automatización.

Corre solo

Un cron en una PC de oficina con Ubuntu. 23:05 y 10:05, corridos cinco minutos para no chocar con la sincronización de git.

Limitaciones conocidas de la recolección



El scraper no recupera el 100% de los tweets

Depende de cuánto scroll carga X antes de cortar la sesión



Las tendencias sólo se extraen el día en curso

X no permite consultas retrospectivas: una corrida fallida es un agujero permanente en la serie



No hay geolocalización real

El campo place es autodeclarado. Medios + tendencias funcionan como proxy




No se capturan los likes de los tweets originales

Sólo los de los comentarios. Se detectó recién durante el análisis exploratorio




El contenido sin texto queda afuera

Imágenes sin descripción: el odio visual no se mide



Proceso de anotación



	Count	Calls to ac	α
HATEFUL	8715	1451	0.579
RACISM	2469	674	0.608
APPEARANCE	1803	34	0.735
CRIMINAL	1642	722	0.618
POLITICS	1428	136	0.509
WOMEN	1332	18	0.531
CLASS	823	135	0.404
LGBTI	818	11	0.555
DISABLED	580	4	0.569

Train dataset:

OT: 1238 / RP: 56.869

<https://huggingface.co/piuba-bigdata>

Classification with and without context - BETO (BERT)

	Binary classification			Multiclass classification		
	RP (only comments)	OT (title)	OT + article	RP (no context)	OT (title)	OT + article
Precision	71.8	74.8	72.8	63	70.2	67.8
Recall	60.2	65.3	64.1	49.9	55.1	54.1
F1	65.5	69.7	68.1	55.1	61.3	59.8
Macro F1	79.8	82.2	81.3	55.1	61.3	59.8

→ La conclusión fue que agregar contexto simple (el tweet original) mejora el desempeño: +4,2 puntos de F1 macro en la tarea binaria y +5,5 en la multietiqueta. Sumar además el cuerpo completo del artículo no mejora nada sino da peores resultados que el contexto simple. Hay diferencias en ciertas categorías aun más marcadas.

Pérez, J.M., Luque, F., Zayat, D., Kondratzky, M., Moro, A., Serrati, P., Zajac, J., Miguel, P., Debandi, Natalia., Gravano, A. and Cotik, V. (2023), "Assessing the Impact of Contextual Information in Hate Speech Detection" <https://ieeexplore.ieee.org/document/10076443>

Pruebas iniciales del MONITOR DDO

Comparación de dos modelos

Se ejecuta en una sesión de JupyterHub (servidor UNC). Ambos modelos corren sobre el mismo comentario de forma independiente.

PySentimiento

robertuito-hate-speech

Umbral 0.50

ETIQUETAS (3)

hateful

targeted

aggressive

BETO

Gianni08/beto_hate_speech_ar_multiclasif

Umbral 0.45

ETIQUETAS (10)

HATEFUL

RACISM

WOMEN

LGBTI

CLASS

POLITICS

DISABLED

APPEARANCE

CRIMINAL

CALLS

Los dos modelos coinciden muy poco entre sí

Medido sobre una muestra de prueba de 1,381,574 publicaciones (comentarios y tweets) clasificados por ambos modelos.

0.25

Índice de Jaccard

Intersección sobre unión de los comentarios marcados como odiosos por cada modelo

0.23

Kappa de Cohen

Acuerdo corrigiendo por azar, se ubica en el rango "leve" de la escala estándar

2.5%

Coincidencia total

De los comentarios marcados como odiosos por al menos un modelo, solo este % lo marcan ambos

Esto refuerza la necesidad de un clasificador propio, entrenado sobre corpus etiquetado manualmente en contexto argentino.

Análisis y visualización



Reproducción de la xenofobia en twitter durante la pandemia de covid-19 en argentina: análisis de representaciones sociales y discursos discriminatorios en comentarios a noticias (2020-2021)

Natalia Debandi & Anahí Gonzalez

El estudio busca identificar y caracterizar las representaciones sociales y configuraciones discursivas asociadas a la xenofobia y el racismo en comentarios de Twitter vinculados a noticias de medios argentinos durante la pandemia de COVID-19, combinando técnicas de procesamiento de lenguaje natural y modelado de tópicos con una interpretación cualitativa situada en la teoría de las representaciones sociales.

- Uso de un dataset preexistente: se reutiliza un corpus construido previamente en el proyecto PIUBAMAS *Big Data y Marginaciones Sociales*
- Filtrado temático: selección de comentarios mediante palabras clave asociadas a migración, extranjería y pandemia.
- Focalización analítica: selección de los 15.303 comentarios clasificados como RACISM, correspondientes a xenofobia y/o racism
- Modelado de tópicos: aplicación de BERTopic para identificar agrupamientos y configuraciones discursivas emergentes del corpus.
- Reducción y consolidación: agrupamiento de los tópicos iniciales en cuatro grandes narrativas, preservando el 99,4% de los documentos clasificados.
- Construcción teórica de los tópicos articulando términos representativos, lectura cualitativa y teoría de las representaciones sociales.

Reutilización de corpus ya clasificados

¿La xenofobia en redes es un fenómeno coyuntural, activado por eventos, o la expresión de un racismo estructural ya normalizado?

1.351.025

comentarios filtrados

116.587

noticias

5,34 %

discriminatorios (HATEFUL)


1,13 %

xenofobia o racismo
(RACISM)

(1) la etiqueta heredada. RACISM mezcla racismo, es decir atributos étnico-raciales, con xenofobia (discriminación por origen nacional)

(2) Cuan representativo es este corpus del debate público general. Ejemplo DNU 70/17


El corpus en el tiempo



El 5 de marzo de 2021 se derogó el DNU 70/2017, con amplia cobertura mediática.

No hay ningún pico. Parece indicar que los debates de política migratoria no activan xenofobia en redes de forma amplia, comparando con los picos la activan los encuadres más individuales y cotidianos


Hateful Tweets Over Time



DISEÑO DEL MONITOR DE ODIO

El desafío de una herramienta en
línea permanente


Pipeline – MONITOR DDO



Cíclico. No termina nunca.

El problema deja de ser metodológico y pasa a ser de arquitectura: qué corre, dónde, cada cuánto, y quién responde cuando falla.

Recolectar




Definiciones

- Unidad de análisis: el comentario. El tweet se recolecta como contexto, para saber qué temas generan reacción.
- Dos fuentes: tendencias de Argentina, diaria a las 23:05; y diez medios de distinta línea editorial, los sábados a las 10:05.
- X no permite delimitar por geolocalización real: el campo place es autodeclarado. Tendencias y medios son la aproximación disponible a una muestra del debate público.
- Los medios se extraen con una semana de retraso, porque los comentarios se acumulan después de la publicación.
- Playwright, sin API oficial. Autenticación por cookies de sesión en un .env que no se versiona
- Un CSV por corrida, consolidados en un parquet único con deduplicación por URL.

Desafíos /pendientes

- Trasladar la recolección a la nube. Ahora en PC de oficina (si falla, las tendencias no admiten consulta retrospectiva: el día que no corre, no existe)
- ¿Qué se hace con los huecos? Un agujero en la serie no es lo mismo que un día sin odio.
- El scraper recupera lo que X le muestra, no el 100 %. La cobertura real no es medible desde adentro.
- Riesgos éticos de la recolección y salvaguardas de seguridad en el guardado. Hay datos personales.
- Las cookies caducan y la cuenta puede ser bloqueada por comportamiento automatizado. Diseño de alarmas permanentes
- Limite de almacenamiento y escalabilidad

Clasificar



Definiciones

- Esquema multietiqueta: un mismo comentario puede recibir varias categorías, porque los discursos son interseccionales.
- Se realizará un proceso de etiquetado (en diseño).
- Limpieza previa: se descartan filas sin texto, contenido que es sólo imagen y textos en alfabetos no latinos.
- Checkpoints reanudables y hash del texto por fila, para detectar si el contenido cambió entre corridas.
- Usar el tweet original como contexto

Desafíos /pendientes de diseño

- Elegir el clasificador/modelo
- Diseñar el mecanismo de etiquetado (concepto, manual, software, etc.)
- En producción se clasifica el comentario aislado, y el campo del tweet de origen guarda sólo 100 caracteres.
- Definir donde correrá el clasificador. Opciones: cluster local o CCAD (FAMAF- Córdoba)

Anonimizar




Definiciones

- Se anonimiza después de clasificar y antes de visualizar. El objetivo es tener el dataset con usuarios clasificado para poder realizar análisis puntuales que incluyan el emisor-destinatario (concepto completo de odio)
- Usuarios: hash SHA-256. Es reproducible, así que se puede seguir la actividad de una cuenta sin conocer su identidad.
- Medios y figuras públicas se exceptúan: su identidad es parte del análisis.
- En el texto libre se reemplazan email, teléfono, tarjeta y DNI, con detección automática de entidades.

Desafíos

- Definir si se anonimizan nombres propios o menciones: hacia quién se dirige el discurso es información sustantiva.
- El hash protege la columna, no la frase: un comentario largo y específico se busca en X y devuelve la cuenta. (si mostramos el comentario)
- Evaluación externa de riesgos y Comité de ética de UNSAM
- Definir esquemas de acceso, seguridad y mecanismo de eliminación del dato
- Como se sostienen los derechos ARCO (pedir eliminación).
- Riesgo de revictimización si se muestra el texto e inferencia fácil de persona

Visualizar




Definiciones

- Se publica el agregado. Los mensajes individuales no van al tablero por defecto: van a informes, con contexto y con responsable.
- Todo indicador tiene que ser autoexplicado: qué mide, sobre qué universo, con qué umbral y con qué fecha de corte.
- Las unidades temporales son el día, la semana y el mes.
- El sistema funciona mediante un mecanismo pre-calculado en una base de datos, no calcula en tiempo real

Desafíos

- Periodicidad. Con cuanto delay se publica. Medir resguardo y cuidado vs capacidad de hablar de actualidad.
- ¿Hay validación humana entre publicación y publicación? ¿Cómo diseñar un mecanismo de control? ¿quien revisa?
- Un pico puede ser un fenómeno o una falla de recolección, y el tablero no los distingue. ¿Cómo identificar la incertidumbre y como mostrarla?

El mock-up: el tablero corriendo sobre datos reales



El período es un control, no un default

Quien mira elige la ventana. El número de portada cambia con ella: no hay "el" dato.

Dos capas, no una

Discriminación (HATEFUL) es el universo; odio (CALLS) es el subconjunto que llama a la acción.

7,5 % y 0,3 %

Son proporciones observadas por el clasificador, no prevalencia real. La distancia entre las dos cosas es el problema abierto.

Actualizado 17 ago 2026

La fecha en la portada es parte del dato: dice cuánto atraso tiene lo que se está mirando.

Gracias

Natalia Debandi – CIAI-UNSAM / CONICET
ndebandi@unsam.edu.ar

SICSS Argentina 2026