

Análisis de la polarización a través de PLN



Presentación

- Juan Manuel Ortiz de Zarate
- Doctor y Licenciado en Cs. de la Computación
- Founder Data Voices, empresa de desarrollo de IA a medida
- Consultor IA en Banco Interamericano de Desarrollo
- Ex docente en Ciencia de Datos y Machine learning en UCA y FIUBA

Polarización

- Polarización social: *intensificación de opiniones opuestas y disminución de puntos de vista intermedios*
- Diversos trabajo señalan que en los últimos años la polarización se ha extendido en distintos países y coyunturas electorales
- Muchos destacan la preocupación por la relación entre polarización y una creciente erosión a la democracia
- Otros señalan que ha provocado una reducción en el crecimiento económico debido al aumento de la incertidumbre sobre las condiciones económicas

Redes sociales

- La irrupción de las redes sociales digitales dió lugar a una nueva dimensión sobre la cual se manifiesta este fenómeno
- Las discusiones que antes se daban sólo analógicamente encontraron un nuevo soporte
- Estas plataformas almacenan todas las conversaciones que en ellas suceden, lo que disponibiliza enormes corpus de datos que antes no existían
- Estos datos permiten realizar nuevos análisis, estudios e incluso intervenciones sobre la polarización



Casos resonantes

- Elecciones EEUU 2016: Cambridge Analytica fue acusada de usar datos personales de millones de usuarios para influir en las elecciones. Utilizaron estos datos para crear perfiles detallados de votantes y dirigirles publicidad política manipuladora, favoreciendo la campaña de Donald Trump.
- Ataque al CONICET: Una Investigación de El Gato y La Caja evidenció la existencia de un ataque coordinado que tenía como objetivo denostar y disciplinar a un sector que estaba quejándose del ajuste en Ciencia y Tecnología en 2016.

Las redes sociales profundizan la polarización

- Pariser et al. : Las RRSS fomentan la división al crear cámaras de eco que refuerzan los sesgos
- Tufekci et al. : Los algoritmos priorizan contenido que genere interacciones, lo que puede incentivar controversias y divisiones
- Calvo et al. : Las redes sociales permiten intervenir intencionadamente la polarización para sacar ventajas



Las redes sociales, profundizan la polarización?

- Bakshy et al. : Los usuarios se exponen a una amplia variedad de puntos de vista, depende de su red.
- Barbera et al. : Las estructuras de comunicación en línea son flexibles y específicas a la situación. Hay tópicos que unen y otros que dividen.
- Boxwell et al. : En algunos países creció la polarización y en otros disminuyó¹. No hallaron una relación entre la penetración de internet en la sociedad y el crecimiento de la polarización




1. En casos como Noruega, Suecia y Alemania se detectó una disminución de la polarización entre 1980 y 2020



Limitaciones

- Definiciones ambiguas y falta de consenso
- Problemas metodológicos
- Cambios rápidos en el entorno en línea
- Calidad de las conversaciones online
- Efectos de la exposición a puntos de vista contrapuestos

La polarización y su relación con el lenguaje



- Khubadush et al. : Infieren modelos que traducen la jerga de una comunidad polarizada a la otra. Infiere que que las comunidades polarizadas esencialmente “hablan diferentes idiomas”.
- Ramponi et al. : Construyen clasificadores que predicen la pertenencia de usuarios a sus comunidades en base al vocabulario que utilizan.
- Lahoti et al. : Logran diferenciar usuarios liberales de conservadores en Twitter a través de sus interacciones y los medios que comparten.
- Tran et al. : Afirman que el estilo del lenguaje es un mejor indicador de la identidad de una comunidad que los tópicos de interés de la misma.


PLN en el estudio de la polarización

- Ha mostrado un enorme crecimiento en su aplicación al estudio de este fenómeno
- Sin embargo, se hallaron varias limitaciones metodológicas
 - Predominio de contextos estadounidenses
 - Datos centrados principalmente en Twitter
 - Falta de conocimiento especializado en la temática
 - Sin foco multi-capa, centrándose en un único nivel (medios, sociedad, líderes y expertos)
 - Crisis de reproducibilidad
 - Falta de interdisciplinariedad

Concepto clave: Embeddings


- Las computadoras no entienden texto, sólo hablan el idioma de la matemática
- Por lo tanto, si quiero desarrollar métodos que utilicen texto necesito modelar el mismo matemáticamente
- Eso son los embeddings, vectores que representan la semántica del texto
- Pueden pensarse como puntos en el espacio, posicionados de forma tal que embeddings de palabras con significados similares se encuentran cerca entre sí y distanciados de palabras con significados muy distintos
- Los embeddings pueden modelar palabras, oraciones o incluso párrafos

King – Man + Woman = Queen



Midiendo la polarización

A través del texto



- DE ZARATE, Juan Manuel Ortiz, et al. Measuring controversy in social networks through nlp. SPIRE 2020

- DE ZARATE, Juan Manuel Ortiz; FEUERSTEIN, Esteban. Vocabulary-Based Method for Quantifying Controversy in Social Media. En ICCS. 2020

Identificación de la Controversia

- Identificar la polarización automáticamente y en tiempo real permite poder accionar sobre ella para intentar mitigarla
- Diversos trabajos de la literatura desarrollaron técnicas y enfoques para esto, tales como:
 - Mejorar la dieta de noticias de los usuarios mediante sugerencias de lecturas
 - Unir las camaras de eco, generando comunicación directa entre los distintos puntos de vista
 - Métodos para defenderse proactivamente ante ataques de otras comunidades




Hipótesis

- Si la controversia es la discusión entre comunidades con distintos puntos de vista
- Si las comunidades poseen jergas distintas y distinguibles
- Entonces se debe poder detectar cuándo en una discusión está habiendo grieta, es decir dos comunidades expresándose de forma distinta o hasta opuesta

Metodología

- Dipole Moment Content es una técnica sistemática para detectar la controversia sobre cualquier discusión en Twitter
- Consiste de un pipeline de 5 estados
 1. Construcción del grafo
 2. Identificación de las comunidades
 3. Entrenamiento del modelo
 4. Predicción
 5. Cálculo de la controversia

Cálculo de la controversia (Propagación)




Experimentos


- Utilizamos 30 discusiones, ocurridas entre Marzo 2015 y Junio 2019
- Abarcamos 4 idiomas: Inglés, Portugués, Español y Francés y 5 regiones
- Para cada discusión tomamos 140 y 280 caracteres de cada tweet para analizar diferencias en la performance
- Para definir la cantidad de tweets necesaria establecimos que el modelo entrenado tiene que ser capaz de identificar con una $p > 0.9$ a un individuo de cada comunidad

Datasets


Kavanaugh




Macri discussion




Bolsonaro discussion




Halsey discussion




#EXODEUX discussion




#KingJacksonDay discussion



Resultados



AUC ROC: 0.92




Método 2: Utilizando únicamente el texto


- Nuestro objetivo es crear un embedding por cada usuario
- Para eso agrupamos los tweets por usuario (pertenecientes a las dos principales comunidades) y los sanitizamos
- Para inferir los embeddings utilizamos dos técnicas distintas: Fasttext y BERT, ambos los utilizamos de manera supervisada
- La idea es que si la polarización se manifiesta las comunidades tenderán a tener sus embeddings en espacios alejados, y en caso contrario se encontrarán mezclados

Ejemplo



Con polarización



Sin polarización



Resultados



Conclusiones

- En este capítulo desarrollamos los primeros métodos sistemáticos a gran escala para cuantificar la controversia a través del texto
- Mostramos que el método funciona en Español, Inglés, Francés y Portugués, que es agnóstico del contexto y que no requiere a un experto del dominio
- Equiparamos la performance con los métodos del estado del arte basados en las estructuras del grafo
- Mostramos que a mayor texto, mejor performance y un incremento lineal del tiempo de cómputo

Casos de estudio


La polarización en Argentina y Estados Unidos



Estudio

- Descargamos todos los tweets que mencionasen a la cuenta @alferdez y @realDonaldTrump entre el 9 de Mayo y 9 de Junio de 2020
- Para comprar la estabilidad de las polarizaciones separamos ambos set de datos en dos “fotos”, una de la primer semana y otra de la última
- Analizamos si los usuarios se mantienen en sus comunidades o tienden a cambiar a medida que pasa el tiempo
- Mediante las técnicas anteriores medimos la polarización de cada país

Los polos se componen de comunidades



Conclusiones

- La polarización es un fenómeno global, sucede en varios países aunque distintos matices
- La polarización se mantiene estable en el tiempo, si bien sus usuarios y tópicos de interés cambian, no lo hacen de forma tal de romper con la grieta
- Los tópicos sobre los que discuten los usuarios están correlacionados a sus posibles cambios de bando
- Si bien la grieta forma polos, en cada uno de ellos podemos notar sub-comunidades que los componen con intereses y enfoques ligeramente distintos entre ellos

Los divergentes

En contextos polarizados



- Kessler, G., Focás, B., ZÁRATE, J., DE, M. O., & FEUERSTEIN, E. (2020). Los divergentes en un escenario de polarización. Un estudio exploratorio sobre los “no polarizados” en controversias sobre noticias de delitos en la televisión argentina. Revista SAAP


Introducción

- Este capítulo se centra en los "no polarizados", explorando si tienen características comunes o si son simplemente una categoría residual.
- Utilizamos métodos mixtos, combinando análisis cualitativos y computacionales, para observar la polarización en interacciones y debates.
- Trabajo de manera interdisciplinaria con colegas de las ciencias sociales
- Dataset: Desgrabaciones de 3 focus grupales realizados en CABA durante Septiembre de 2017
- Las discusiones se centraron en temas como medios de comunicación, inseguridad, violencia de género y corrupción

Método

- Este procedimiento está basado en la técnica desarrollada para la medición de la controversia
- Dado que los datos de desgrabaciones no resultaban suficientes para entrenar Fasttext, el modelo fue entrenado sobre discusiones de Twitter argentina durante el mismo período en que se realizaron los Focus
- Utilizamos dicho modelo para generar los embeddings de cada intervención
- Luego estimamos los clusters que estos embeddings forman mediante Agglomerative Clustering
- Finalmente calculamos el nivel de divergencia de cada participante en base a cuánto variaron sus intervenciones entre una comunidad y otra

+ Divergencia



+ Extroversión

Resultados

Conclusiones

- Se categorizaron como divergentes a aquellos participantes del cuadrante superior derecho
- Comparten una molestia con la forma en que los medios polarizan la información. Valoran la objetividad y se sienten incomodados por la falta de esta, así como por el tono agresivo o descalificador de los periodistas.
- Mantienen una actitud crítica pero no extremista hacia los medios. No buscan verdades absolutas, sino que aceptan la complejidad de la realidad y la diversidad de perspectivas
- No existe un "tercer polo discursivo", sino que los divergentes integran elementos de ambos polos principales, formando opiniones propias que pueden parecer contradictorias desde una perspectiva polarizada

Conclusiones

- Ejemplos de opiniones divergentes:
 - Pueden criticar la corrupción en ambos gobiernos (kirchnerista y macrista)
 - O combinar un fuerte compromiso con el tema del femicidio con la aceptación de la violencia contra delincuentes
- Al expresar dudas y valorar la pluralidad de opiniones, contribuyen a mitigar la polarización en las interacciones, ya que no están inmersos en la polarización afectiva y su posición es más escuchada por los demás

Herramientas para el análisis cross-plataforma

En la comunicación política



Introducción

- Las redes sociales se han convertido en herramientas clave para los políticos. Facilitan la comunicación directa con el electorado y la difusión de mensajes
- "New media, new politics 2.0": uso sofisticado de tecnología digital y múltiples plataformas. Comienzo aprox 2008
- Limitaciones de la mayoría de los estudios en este sentido
 - En general se basan en períodos de campañas en los países centrales
 - Suelen centrarse en una sola plataforma
 - Analizan más metadatos que contenidos.

Nuestro trabajo




- En este estudio desarrollamos técnicas computacionales para analizar cómo el comportamiento de los políticos en redes sociales puede influir en la polarización social.
- Conformamos un equipo interdisciplinario con el objetivo de entender las estrategias de comunicación de los políticos
- La pregunta que nos hicimos fue **¿Comunican igual en todas las redes?**
- Analizamos la comunicación de 50 figuras políticas argentinas en Twitter, Facebook e Instagram durante todo 2020

Hipótesis


1. Cada espacio elige Facebook e Instagram para hablar sobre los temas propios, y en Twitter se debaten los temas sin propiedad exclusiva
2. Los temas en común entre Oficialismo y Oposición no sólo incluyen confrontaciones
3. Oficialismo y Oposición suelen enunciar mensajes con sentimiento (positividad/negatividad) distinto dependiendo de la red por la que se expresan.
4. Twitter es la plataforma donde hay mayor proporción de mensajes que expresan sentimientos negativos
5. En Twitter los políticos tienden a interpelarse más entre sí

Métodos

- Mediante clustering de embeddings detectamos los tópicos discutidos. Luego analizamos de qué sector vienen los posts de cada uno para estimar la propiedad de los mismos.
- A través de redes neuronales estimamos el sentimiento y la toxicidad de los posts
- Mediante un árbol de decisión identificamos si era posible distinguir la red de los usuarios en base a los tópicos discutidos
- Mediante análisis de frecuencia de las palabras analizamos si había diferencias en los lenguajes utilizados en cada red



Resultados



Conclusiones

- Aportamos técnicas innovadoras para el análisis comparativo de textos en redes sociales, aplicables a un rango más amplio de medios y figuras públicas, en diferentes idiomas
- La atención exclusiva en Twitter puede llevar a una percepción conflictiva y superficial de la política
- Estos hallazgos subrayan la importancia de un enfoque cross-plataforma para captar la complejidad y los matices de la comunicación política actual
- Tener una comprensión más abarcativa de la comunicación política en redes sociales permite desarrollar mejores estrategias para promover un diálogo más constructivo y menos polarizado

Midiendo el espectro ideológico

De las comunidades digitales




Introducción

- Durante décadas se ha debatido sobre la interacción de dos fuerzas duales en Internet: la **integración** y la **fragmentación** social
- Preocupa la aparente tendencia a agruparse en cámaras de eco homogéneas y la inquietud sobre si las redes social empujan a posturas más extremas
- Cuantificar empíricamente la composición social de las comunidades en línea y, a su vez, la organización social, plantea un desafío enorme debido a la naturaleza de sus datos
- En este capítulo proponemos una técnica para cuantificar la posición en espacios ideológicos basada en el texto publicado por las comunidades en Reddit

Método


- Primero calculamos los embeddings de cada subreddit en base a los textos de sus posts, utilizando Fasttext entrenado sobre estos datos y LLMs sin entrenamiento extra
- Luego estimamos su organización social mediante los siguientes pasos



Evaluación

- Para estimar la calidad de nuestros resultados tomamos como ground-truth la categorización hecha por Waller et al.
- Comparar la similitud entre dicha organización de las comunidades y las resultantes de nuestro método es equivalente a comparar rankings
- Por lo tanto utilizamos las métricas de comparación de rankings: Kendall Tau y RBO
- Dada la naturaleza de nuestro problema, es más importante estimar correctamente las comunidades de los extremos que las del centro
- Para tener en cuenta esto, también desarrollamos nuestras propias métricas

Comparison of Models on Subreddits 2018




Resultados

Conclusiones

- Desarrollamos un pipeline impulsado por PLN diseñado para estimar la organización de las comunidades en línea
- Los resultados se equiparan al de trabajos anteriores donde utilizaron las interacciones para hacer sus estimaciones
- Hallamos que los LLMs modelan la dimensión ideológica, lo que permite hacer este y otros análisis a través de ellos
- Nuestra técnica también sirve como método de interpretación sobre que modelan estas nuevas herramientas emergentes
- Actualmente la estamos utilizando para ver si también modelan el mundo físico

Resumiendo




Aportes por capítulo

- Técnicas para medir la polarización a través del texto
- Técnica para identificar comunidades a través del texto a lo largo del tiempo
- Identificación de los “divergentes” en focus groups
- Técnicas para analizar comportamiento cross-plataforma
- Técnica para medir el espectro ideológico a través del texto
- Análisis de los Sesgos de los LLMs respecto a nuestra cultura

Corolario

Llevando la Tesis a la práctica





- Finalizando mi tesis conocí a Rob Romero, el fundador de una ONG norteamericana cuyo objetivo es despolarizar a la sociedad
- Comencé trabajando con él como asesor en cuestiones de IA y despolarización
- Al poco tiempo fundé Data Voices y le propuse construir en conjunto una plataforma para generar intervenciones despolarizantes a escala mediante IA
- Así nació Normsy, y lo que empezó como un simple prototipo hoy, 3 años después, se convirtió en algo mucho más grande!