



factor~data
EIDAES_UNSAM



Summer Institute in Computational Social Sciences
Buenos Aires-Argentina | 2026


Summer Institute in Computational Social Sciences

Cap. 0. Vectorización... el ABC del NLP




Primero que nada... los materiales

https://gefero.github.io/factor_data_tuto_NLP_SICSS/



factor-data
EIDAES_UNSAM

“Podemos imaginar que si conociéramos el conjunto de narraciones que circulan en la Ciudad de Buenos Aires en un día conoceríamos un tipo particular de funcionamiento de esta ciudad con bastante precisión. (...) Si tuviéramos la posibilidad, fantástica, de disponer de todas esas narraciones, podríamos detectar las grandes formas, los grandes núcleos formales a partir de los cuales se construyen **los grandes relatos sociales.**” (p. 60-61)



- Todo el tiempo estamos produciendo textos

- Charlas
- Entrevistas
- Posts
- Redes sociales



- ¿Cómo podemos aprovechar esos textos en la investigación?






“Mucha gente ha leído más y mejor que yo, por supuesto, pero eso tampoco basta: aquí hablamos de cientos de lenguas y literaturas. Todo indica que leer ‘más’ no es la solución. En especial, porque hemos comenzado a descubrir (...) la enormidad de lo no leído (...) pero el punto es que existen treinta mil novelas británicas del siglo XIX o cuarenta o cincuenta, sesenta mil: nadie lo sabe a ciencia cierta, nadie las ha leído, nadie las leerá. Y, además, hay novelas francesas, chinas, argentinas, estadounidenses.

Leer ‘más’ siempre es bueno, pero no es la solución” (p. 59)



Aplicaciones usuales

SENTIMENT ANALYSIS



factor-data
EIDAES_UNSAM

Clasificación - Aplicaciones

Automatización de procesos
para la construcción de bases
de datos de protestas

[\[Hanna, 2017\]](#)




Figure 1: MPEDS pipeline with training.


No supervisado - Aplicaciones

Posiciones ideológicas en proyectos de ley

[\[Gerrish y Blei, 2012\]](#)

Terrorism	Commemorations	Transportation
terrorist	nation	transportation
september	people	minor
attack	life	print
nation	world	tax
york	serve	land
terrorist attack	percent	guard
hezbollah	community	coast guard
national guard	family	substitute

Labeled topics



The issue-adjusted ideal point model

Figure 3: Left: Top words from topics fit using labeled LDA [6]. Right: the issue-adjusted ideal point model, which models votes v_{ud} from lawmakers and legislative items. Classic item response theory models votes v using x_u and a_d, b_d . For our work, documents' issue vectors θ were estimated fit with a topic model (left of dashed line) using bills' words w and labeled topics β . Expected issue vectors $\mathbb{E}_q[\theta|w]$ are then treated as constants in the issue model (right of dashed line).

Del texto al dato



El problema

<<SimpleCorpus>>
Metadata: corpus specific: 1, document level (indexed): 0
Content: documents: 3

[1] a bailar a bailar | que la orquesta se va | sobre el fino garabato | de un tango nervioso y llerdo | se ira borrando el recuerdo | a bailar a bailar | que la orquesta se va | el ultimo tango perfuma la noche | un tango dulce que dice adios | la frase callada se asoma a los labios | y canta el tango la despedida | vamos! a bailar! | tal vez no vuelvas a verla nunca | y el ultimo tango perfuma la noche | y es te es el tango que dice el adios | a bailar a bailar | que la orquesta se va! | quedara el salon vacio | con un monton de esperanzas | que iran camino al olvido | a bailar a bailar | que la orquesta se va!

[2] este tango nacio para bailarse | y asi hamacarse muy suavemente | oigan ustedes este compas... | es muy sencillo bailar el tango | un doble paso despues descanso | la media vuelta la vuelta entera | y siempre junto a la companera | este tango nacio para bailarse | no hay que quedarse mirandolo

[3] nacio en la calle quito | entre boedo y colombres | barrio de tauras de hombres | de timbas y de garitos | mi recuerdo es muy estricto | de proscenio un corralon | modesto fue su blason | y la dulce purrética | se lavaba la carita | en el viejo pileton | amante del varieté | sonaba con ser artista | comenzo como corista | hasta llegar a vedette | piernas tipo mistiguette | cintura bien contorneada | anatomía envidiada | y un rostro angelical | para que plumas y percal | lucieran como hermanadas | siempre causo sensacion | en cine radio y teatro; | se volco al dos por cuatro | con sentida emocion | triunfo en television | y nadie podra dudar | fue figura consular | en todos los escenarios | recogio aplausos a diario | se llamaba beba bidart

MAS_500	AGLOMERADO	PONDERA	CH03	CH04	CH05
Agglomerados segun tamano	Codigo de Aglomerado	Ponderacion	Relacion de parentesco	Sexo	Fecha de nacimiento (dia, mes y año)
N		8	108	2	2 03/06/1990
N		8	108	3	2 29/12/2005
N		8	108	3	1 26/01/2018
N		8	108	1	2 30/03/1978
N		8	108	3	2 20/09/2009
N		8	141	1	1 26/04/1967
N		8	221	1	1 15/03/1955
N		8	221	2	2 25/04/1956
N		8	221	3	2 10/06/1994
N		8	221	1	1 22/07/1944
N		8	221	3	1 23/08/1985
N		8	309	1	1 14/06/1976
N		8	309	2	2 17/06/1978
N		8	309	3	2 20/07/1997
N		8	309	3	1 19/10/2001
N		8	309	1	2 02/01/1967
N		8	309	3	2 29/06/1982
N		8	88	1	1 15/08/1974



Grado de estructuración



factor-data
EIDAEs_UNSAM



El problema

- No estructurados
- No hay modelo predefinido
- No hay orden
- NLP => tratar de detectar patrones en estos datos no estructurados
- Operación fundamental: **vectorización**




¿Cómo representamos los datos?

- Estructura tripartita (o cuatripartita) del dato
 - Unidad de análisis
 - Variable
 - Valor
- Procedimientos de construcción (indicadores)




¿Qué es un dato?

- La estructura del dato es una **gramática invariante**: un conjunto de funciones que están comprometidas en toda “unidad de información”.
- “Si hay dato, entonces estarán comprometidas, al menos, las cuatro funciones descritas”
- “Si alguno de estos componentes falta, entonces no hay dato, o la información resulta incompleta”



El cuarto elemento...

- Samaja menciona un cuarto componente de la estructura del dato: el indicador (el nombre es confuso y no es el más apropiado)
- Es el **procedimiento** aplicado a una **dimensión** de la variable para establecer qué valor le corresponde a una unidad de análisis determinada.
- **Interfaz o sistema traductor** entre el plano de los conceptos teóricos y el plano de la facticidad o realidad empírica




Un ejemplo...

[y]	=	[F]	[x]
Valor Bebedor moderado		Variable Alcoholismo	Unidad de análisis Daniel Pérez
			
Indicador: (valor del i.: de 1 a 50 cc)		Dimensión: cantidad de alcohol que bebe Procedimiento: preguntas al sujeto	

¿Qué es un dato?

- Esta gramática no presupone necesariamente ni datos cuantitativos, ni que el formato de presentación de la información sea tabular

“La misma estructura invariante puede encontrarse con independencia de la modalidad de presentación o ubicación de los componentes estructurales del dato.” (Ynoub 2015: 275)



¿Qué es un dato?

- Genogramas
- Sistemas de parentesco en tribus
- Rol del “avunculado” (relación con el tío materno)





Figura 1.



Ejercicio

- Pensar y bosquejar la forma de una matriz de datos basada en los genogramas de Levi-Strauss.
- ¿Cuál es la estructura del dato?
 - Unidades
 - Variables
 - Valores
 - Indicadores
 - Procedimientos
 - Dimensiones

LENGUAJE Y PARENTESCO




Figura 1.

Ejercicio

MATRIZ DE SISTEMAS PARENTALES — LÉVI-STRAUSS, ANTROPOLOGÍA ESTRUCTURAL

Sistema	Linealidad	Alianza esposo = esposa	Consanguinidad hno — hna	Filiación padre \ hijo	Avuncular tío mat. — sobrino
Trobriandés	matrilineal	+	-	+	-
Circasiano	patrilineal	-	+	-	+
Siuai	matrilineal	-	+	+	-
Tonga	patrilineal	+	-	-	+
Lago Kutubu	patrilineal	-	+	+	-

● + relación positiva / solidaria ● - relación negativa / tensa matrilineal descendencia por línea materna

patrilineal descendencia por línea paterna





Figura 1.

¿Qué es un dato?

- ¿Cuál es la estructura del dato?
 - Unidades
 - Variables
 - Valores
 - Indicadores

GRAFICO 7.1 Sectores de actividad de los puestos de trabajo de los trabajadores entrevistados según tipo de entrevistado. Chaco (2012-2013)



- * Combina varios sectores: desmonte y venta de maquinaria
- ** Se trata de una metalúrgica que, además, presta servicios de cosecha
- *** Diversos sectores (changas varias)
- **** Recoge residuos en basural cercano
- ***** Trabaja como peón general en INTA
- ***** Se trata de fabricación de vasos con botellas recogidas del basural (informal)

Fuente: elaboración propia sobre trabajadores entrevistados

¿Qué es un dato?

NOMBRE DE REFERENTE Y	TRAYECTORIA PROFESIONAL Y ANTIGÜEDAD COMO REFERENTE EN ESTA	DESCRIPCIÓN DE LA ESCUELA	EJES DE TRABAJO	MIRADA SOBRE EQUIPO	DOCENTES: PERFIL, VALORACIÓN DE ESCUELA, CONCENTRACIÓN DE HORAS, INVOLUCRAMIENTO	ALUMNOS: CARACTERÍSTICAS PROCEDENCIA, MOTIVOS DE
PERLA, Escuela Normal	2011 empezó su tarea como referente, antes trabajaba en escuela (por más de 20 años): "Yo hice carrera ahí adentro" (fue tutora, profe, coord de tutorías, asesora) (4:30) // Empieza a capacitarse hace años en fortalecimiento institucional. La convocan desde supervisión. Trabaja en otras cuatro escuelas.	"Es una escuela chica" (4:25): En cada turno (My T) una sola división por año "con lo cual uno puede manejar mejor los datos" (4:30) A la mañana: van los chicos que vienen de primaria y la tarde: resto de chicos q se inscriben desde otras primarias. Hay "nivel bien diferente" (enfatisa) Desgranamiento mayor en TT (5:30). Cuando los chicos de la mañana se llevaban materias, repetían 2 de 34 y a la tarde 10 de 34. Como AP insistía en equiparar nivel del TM con TT. (6:08). // Ult. años mucho trab de fortalecimiento para subir nivel (acorde a univ.): "se fue levantando el nivel en 4to y 5to" (7:50), también fue generando desgranamiento en 4º "muchos no se animaban y se iban en 5º" (8:00) // "tiene una buena gestión de nivel medio" Hay buenos equipos de docentes, de tutores, de preceptores. (32:00) fuimos construyendo ideas parecidas, la vice anterior trabajó mucho con los enfoques, qué tipo de enseñanza queremos, qué alumnos, uno está imbuido en esta mirada x eso nos resultó shockeante el ingreso de docentes nuevos, (...) que trabajaban x su salario y sin un compromiso muy sincero	Preparar para la universidad (sistema preuniversitario) - Alto nivel académico - Fortalecer primeros años - Igualar TM con TT -	Buena gestión. VD concurso 2011 y ganó, pero hace 25 años que está en escuela. Hay en normal 1 rector y vicerrector para todos los niveles y luego VD para el nivel medio.	2011 se unificaron listados y llegó gente nueva "hubo q trabajar con profesores para que se adecuaran al nivel de la escuela" (31:00 aprox) Tiene buenos equipos docentes, sobre todo en área de sociales (quizá porque son más flexibles que los de exactas) (31) Pocos profes porque es escuela chica. "Hay dos de biología x ej, de lengua hay 4 o 5 con los 2 nuevos; sociales es área que tiene mas cantidad de docentes xq hay más materias. Hay equipos de trabajo. Forman buenos equipos. Habla de diversidad en plantel docente y	Los chicos q llegan a 3ero adquirieron el hábito ser alumnos de esa esc, entonces ya se quedan... a pesar de que sigue habiendo repitencia, pero no tanta como en 1ero. (8:30). Veíamos dificultad en 3er año... // Son chicos del barrio "que conocen la escuela y quieren la escuela, los padres sobre todo" (2800 aprox), en TT llegan de otras escuelas (con muchas falencias) y en TM son los de primaria de escuela. Deben llegar x boca a boca. Los que van a primaria, se quedan en secundaria. "Tomar primer año como periodo de

¿Cómo representar “matemáticamente” un texto?



	As You Like It	Twelfth Night	Julius Caesar	Henry V
battle	1	0	7	13
good	114	80	62	89
fool	36	58	1	4
wit	20	15	2	3

Figure 11.3 The term-document matrix for four words in four Shakespeare plays. Each cell contains the number of times the (row) word occurs in the (column) document.

- As you like it = [36, 1]
- Twelfth Night = [58, 0]
- Julius Cesar = [1, 7]
- Henry V = [4, 13]







Figure 11.5 A spatial visualization of the document vectors for the four Shakespeare play documents, showing just two of the dimensions, corresponding to the words *battle* and *fool*. The comedies have high values for the *fool* dimension and low values for the *battle* dimension.



¡Me encanta esta película! Es dulce,
pero con humor satírico. El
diálogo es genial y las
escenas de aventura son divertidas...
Logra ser fantasiosa
y romántica mientras se ríe
de las convenciones del
género de cuentos de
hadas. Se la
recomendaría a casi
cualquiera. La he visto varias
veces, y siempre me alegra
volver a verla cuando
tengo un amigo que aún no
la ha visto!



aventura	1
amigo	1
aún	1
cuentos	1
diálogo	1
divertidas	1
dulce	1
el	2
género	1
hadas	1
humor	1
la	8
me	2
película	1
romántica	1
satírico	1
siempre	1
veces	1
visto	2
y	4
...	...




Bag of Words (BoW)

- Representación de cada documento en función de las palabras que contiene
- Características:
 - Es simple de generar
 - Se asume que las palabras son “independientes”
 - Los vectores son claramente no independientes
 - La gramática y el orden de las palabras se pierden



Document-Term Matrix (DTM)




Document-Term Matrix (DTM)

Palabras, bigramas,
trigramas, lemas, solo la
raíz de la palabra...

F términos

Matriz $M =$



Frecuencia del término

Métricas (TF, IDF, TF-IDF)

- Podemos pensar en dos dimensiones de las frecuencias de los términos de un corpus...
 - Un término t es más **importante** si es más frecuente en un documento d de un corpus C determinado.
 - A su vez, t es más **informativo** del contenido de un documento d si está presente en pocos documentos y no en todos de C .
- Mirar tanto la frecuencia de t a lo largo de todo el corpus C y al interior del documento d .



Métricas (TF, IDF, TF-IDF)

- $c(t, d)$ es el conteo "crudo" del t en el documento d
- $rtf(t, d) = c(t, d)$
- Hasta aquí estamos en el esquema BoW crudo.
- Problemas:
 - El largo de los documentos suele ser variable
 - En general, la información acerca del sentido no crece de forma proporcional a la ocurrencia de t en un d
- Entonces, hay normalizaciones alternativas
 - Binaria: 0, 1
 - $TF(t, d) = \frac{c(t, d)}{\sum c(t, d)}$
 - Log: $logtf = 1 + \log(c(t, d))$



Métricas (TF, IDF, TF-IDF)

- Insumo para una medida de la informatividad de un término a lo largo de C

$$DF(t) = \log \frac{df(t)}{|C|}$$

Donde

- $df(t)$ es la cantidad de documentos en C que contienen el término t
 - $|C|$ es el tamaño del corpus C , es decir, el total de documentos en C
-
- Cuanto mayor es $DF(t)$ menor es la informatividad de un término. Entonces, se calcula su inversa (IDF):
 - $IDF(t) = \log \frac{|C|}{df(t)}$



Métricas (TF, IDF, TF-IDF)

- Entonces, $tf(t, d)$ es una propiedad del documento y $IDF(t)$ es una propiedad del corpus
- Combinamos ambas en una medida llamada Term Frequency-Inverse Document Frequency (TF-IDF)

- $TFIDF(t) = tf(t, d) \times IDF(t)$

- Valores altos de $tf(t, d)$ y valores altos de $IDF(t)$ -o sea, valores bajos de $DF(t)$ arrojan valores altos de $TFIDF(t)$.
- O sea, términos t frecuentes en d y poco frecuentes en C .



Un flujo de trabajo “típico” en NLP



Flujo de trabajo en NLP - Preprocesamiento

- Limpieza del texto (texto característico de los formatos)
- Cambiar mayúsculas por minúsculas
- Eliminar signos de puntuación y caracteres extraños (#\$%&?!.,)
- Eliminar números (1,2,3,4...)
- Eliminar “stopwords”



Flujo de trabajo en NLP - Preprocesamiento

- Exclusión de palabras muy comunes con poco valor para recuperar información del documento o corpus
- La cantidad de ocurrencias de una palabra en el texto determina si es o no una “stopword” cuanto más ocurrencias existan menos relevancia tiene en el texto.
- Artículos, pronombres, preposiciones, y conjunciones.
- Reducir el tamaño del texto para analizar, eliminando aproximadamente el 30 % o 40 % de dichas palabras.



Flujo de trabajo en NLP - Preprocesamiento

- Limpieza del texto (texto característico de los formatos)
- Cambiar mayúsculas por minúsculas
- Eliminar signos de puntuación y caracteres extraños (#\$%&?!.,)
- Eliminar números (1,2,3,4...)
- Eliminar “stopwords”
- Tokenización...



Flujo de trabajo en NLP - Preprocesamiento

- Tokenización: proceso que divide una secuencia (por ejemplo, una oración) en *tokens*
- Un *token* puede ser pensada como una unidad útil para el procesamiento semántico (oraciones, párrafos, documentos, etc.)
- Sistemas de escritura occidental: los espacios en blanco y ciertas formas de puntuación (puntos, comas, etc.) son delimitadores útiles para identificar tokens



Flujo de trabajo en NLP - Preprocesamiento

- Input:
 - [No es la conciencia (...) la que determina su ser sino (...) el ser social lo que determina su conciencia.]
- Output:
 - [No], [es], [la], [conciencia], [la], [que], [determina], [su], [ser], [sino], [el], [ser], [social], [lo], [que], [determina], [su], [conciencia]

Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”



Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”



Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”

“Affect” “Affect” “Affect” “Affect” “Affect” “Affect”



Flujo de trabajo en NLP - Preprocesamiento



Reducir las palabras a su raíz

Y poder “reducir” la complejidad del dataset

“Affectation” “Affects” “Affections” “Affected” “Affection” “Affecting”

“Affect” “Affect” “Affect” “Affect” “Affect” “Affect”

Inconveniente: No funciona siempre. Hay palabras que **su raíz depende del contexto** de la oración. Se requiere un **análisis morfológico**.

Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)



Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)

El lema es la palabra que nos encontraríamos en el diccionario tradicional:



Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)

El lema es la palabra que nos encontraríamos en el diccionario tradicional:

- singular para sustantivos (“Mesa” -> “Mesas”)
- masculino singular para adjetivos (“guapas” -> “guapo”)
- infinitivo para verbos (“dije”, “diré”, “dijéramos” -> “decir”)



Flujo de trabajo en NLP - Preprocesamiento

Lemmatization

En vez de cortar a la raíz podemos buscar su “lema” (también llamada “forma canónica”)

El lema es la palabra que nos encontraríamos en el diccionario tradicional:

- singular para sustantivos (“Mesa” -> “Mesas”)
- masculino singular para adjetivos (“guapas” -> “guapo”)
- infinitivo para verbos (“dije”, “diré”, “dijéramos” -> “decir”)

Similar a **stemming** ya que mapea muchas palabras a una sola pero el resultado de **lemmatization** es una palabra mientras que en stemming puede no serlo



Vamos al notebook...

